受脑启发的 4 自由度定位-建图：前庭-视觉互补融合与空间细胞

Haidong Wang (王海东), Rongbo Yang (杨荣波) 湖南工商大学
中国长沙, 410205
Email: open@hutb.edu.cn

***Abstract*—受脑启发的空间认知为自主定位提供了可解释的替代方案, 用以替代不透明的学习方法。然而, 现有的受脑启发框架仍局限于 2D 环境或简化的视觉处理, 在困难条件下缺乏鲁棒的 3D 空间表征。为克服这些局限, 本文提出 NeuroLocMap——一个将定位-建图框架扩展到 3D 空间内 4 自由度状态估计的受脑启发框架, 融合了前庭-视觉互补融合与海马-内嗅空间表征。该框架由双流视觉处理（腹侧通路负责识别、背侧通路负责运动）、前庭 IMU 建模、用于位置编码的面心立方（FCC）晶格 3D 网格细胞, 以及用于闭环检测的经验式认知建图组成; 在 10 状态 EKF 核之上, 两个高层校正补全系统: 在线的、仅尺度的单目校正（冻结深度基础模型之上的轻量回归头）与基于学习嵌入的闭环线。在涵盖仿真城市驾驶（CARLA Town05/03/07/10HD）与真实高速公路驾驶（KITTI 07）的五个场景上的实验表明, 全系统在两种评估口径下于全部五个场景上优于 10 状态 EKF 视觉-惯性基线——在仅形状的全 Sim(3) 重拟合（吸收全局尺度的上界）下改善 16.5–59.3%, 在更严格的 SE(3) 刚性对齐（错误度量尺度无法被吸收）下改善 1.5–33.9%——并相对单目视觉里程计改善 33.7–68.8%。在专门的闭环基准上, 经验地图重锚定相对 EKF 基线多恢复 9 倍累积全局漂移（44.24 m 对 398.05 m 锚定 Sim(3) 口径）。系统以实时运行（CPU 上约 31 FPS）, 其学习组件一次训练、零样本部署, 并输出可解释的拓扑经验地图。**

***Index Terms*—受脑启发的定位-建图, 前庭-视觉融合, 海马空间细胞, 视觉地点识别, 认知建图**

I. 引言

在复杂 3D 环境中的空间定位与建图是自动驾驶、移动机器人与智能交通系统的基石 [1]。作为自主设备的核心感知模块, SLAM 直接支撑所有自主运动规划与执行。现代实用方案通常组合相机、IMU, 有时还加入 GNSS, 以实现鲁棒的位姿估计 [2]。传统 SLAM 方案大多采用优化或滤波框架求解位姿, 但在模型可解释性与计算资源消耗上通常存在明显缺陷。

有趣的是, 蝙蝠等生物通过融合视觉与前庭信号以及海马空间细胞完成 3D 导航 [3], [4], [5], [6], [7]。这些神经机制使受脑启发的定位框架在可解释性与计算效率上优于传统 SLAM。

然而, 将这些生物学原理转化为实用的机器人系统面临若干挑战。第一, 现有仿生框架大多在 2D 中运行, 而实际部署需要鲁棒的 3D 空间表征。第二, 经典视觉模板匹配对光照与视角变化敏感, 限制了困难环境下的地点识别性能。第三, 一种将视觉里程计与惯性测量相结合、且不依赖 EKF 等计算昂贵滤波器的简单而有效的融合策略, 在受脑启发定位框架中仍未被充分探索。

为应对这些挑战, 本文提出 NeuroLocMap——一个扩展到 3D 空间内 4 自由度位姿估计（位姿 x、y、z、ψ）的受脑启发定位-建图框架, 集成了双流视觉前端（腹侧通路用于场景识别、背侧通路用于运动提取）与前庭前端（用于 IMU 处理）, 并以互补滤波实现多感官融合。该框架采用 3D 网格细胞与多层头部方向细胞进行空间表征, 并采用作为类海马情景记忆的多层经验地图用于地点识别与漂移校正。对于在相对平坦地形（如城市道路、室内地面）上运行的地面车辆, 姿态由偏航角 ψ 主导, 俯仰与横摆变化通常受车辆动力学约束（$< 5^\circ$）。我们的 4 自由度表征为这类场景提供了高效的定位-建图 [8], [9]。

本文的贡献总结如下:

- 我们提出一种统一的受脑启发架构, 将双流视觉处理与前庭建模、海马-内嗅空间表征耦合, 用于 4 自由度定位与建图。
- 我们开发了受皮层启发的视觉处理, 采用显式算子构建视觉模板, 将模板数从 5（RatSLAM 典型值）提升到评估序列中最多的 964 个（提升 192 倍以上）, 从而在困难光照与视角变化下实现更细粒度的地点判别。
- 我们设计了一种用于前庭-视觉集成的轻量互补融合策略, 无需计算昂贵的滤波器, 在 CPU 上实现约 31 FPS 的实时性能; 并以两个高层校正补全系统——在线的、仅尺度的单目校正头与基于学习嵌入的闭环线——两者均仅在仿真上训练一次、部署时零样本。
- 我们在五个多样化场景（CARLA Town05 / 03 / 07 / 10HD, KITTI 07）上验证该框架: 全系统在两种评估口径下于全部五个场景上优于 10 状态 EKF 视觉-惯性基线（Sim(3) 仅形状上界: +16.5–59.3%; SE(3) 刚性: +1.5–33.9%）, 相对单目 VO 改善 +33.7–68.8%, 且在专门的闭环基准上其经验地图重锚定相对 EKF 多恢复 9 倍累积全局漂移（44.24 m 对 398.05 m 锚定 Sim(3) 口径）, 同时将可解释的拓扑经验地图作为定位的副产品输出。

II. 相关工作

我们总结了受脑启发的定位-建图系统在不同方面的研究工作。

A. 视觉 *SLAM* 与传感器融合

视觉 SLAM 在过去二十年中取得了重大进展。Mur-Artal 等人提出了 ORB-SLAM [10], 它提取稀疏 ORB 关键点以实现鲁棒的实时位姿估计, 已成为该领域广泛使用的基线。Engel 等人开发了 LSD-SLAM [11] 与 DSO [12], 它们直接在像素强度上运算而无需特征提取, 在纹理丰富的环境中实现半稠密重建。在闭环检测方面, Cummins 与 Newman 提出了基于词袋模型的概率方法 FAB-MAP [13], 而 Arandjelovic 等人引入了 NetVLAD [14], 通过端到端学习地点描述子实现鲁棒的地点识别。然而, 这些方法存在关键局限: ORB-SLAM 需要足够的纹理（通常每帧 >100 个特征点）, 在弱纹理环境中会失效; 而 DSO 等直接法对运动模糊敏感且需要光度标定。两类方法都有相当高的计算开销——ORB-SLAM 的特征提取与匹配主导了处理时间, 而 DSO 的稠密光度优化限制了其在嵌入式平台上的实时性能。

将 IMU 与相机集成, 通过提供与光照无关的运动估计来弥补视觉 SLAM 的局限。Mourikis 与 Roumeliotis 提出了 MSCKF [15], 这是一种紧耦合视觉-惯性估计器, 通过多状态约束优化实现高精度。Qin 等人开发了 VINS-Mono [16], 将紧耦合优化与闭环相结合, 实现鲁棒的单目视觉-惯性里程计。Mahony 等人 [17] 与 Madgwick 等人 [18] 提出了利用频域传感器特性的互补滤波方法——视觉里程计提供精确的低频估计, 而 IMU 捕获高频动力学。然而, MSCKF 与 VINS-Mono 这类紧耦合方法需要仔细初始化 IMU 偏置与尺度, 涉及复杂的雅可比推导, 且缺乏生物学可解释性。为克服这些局限, 我们采用一种受生物启发的互补滤波策略, 模仿生物的前庭-视觉整合 [19], [20], 以最少参数调优提供可解释的传感器融合, 并避免联合非线性优化的计算负担。

B. 受脑启发的空间认知

生物导航系统通过专门的神经回路实现鲁棒的空间认知。O'Keefe 与 Dostrovsky 在海马中发现位置细胞 [21], 它们在特定位置发放并形成认知地图。Hafting 等人在内嗅皮层中发现网格细胞 [22], 其周期性六角形发放模式提供了度量路径积分。Taube 等人鉴定出头方向细胞 [23], 它们像内部罗盘一样编码朝向。Moser 等人 [24] 对这些空间细胞如何协同工作以实现导航进行了全面综述。Finkelstein 等人的最新发现表明, 蝙蝠拥

有 3D 位置细胞、具有面心立方（FCC）晶格结构的 3D 网格细胞以及 3D 头方向细胞 [25], [6]，为体积化空间表征提供了生物学依据。

Milford 等人开创了 RatSLAM [8], [26]，通过实现位置细胞动力学的连续吸引子网络与用于闭环的经验地图，将啮齿动物空间认知转化为机器人技术，成功演示了长达 66 km 的街区规模建图。Steckel 与 Peremans 开发了 BatSLAM [27]，将仿生 SLAM 扩展到声呐感知。Yu 等人提出了 NeuroSLAM（未发表工作），将其扩展到基于 CNN 视觉处理的 3D 位置编码。Lowry 等人 [28] 分析了空间地图中度量-拓扑的二象性：度量地图提供几何精度但扩展性差，而拓扑地图支持鲁棒闭环但缺乏度量精度。然而，现有仿生框架存在三个关键局限：(1) 大多在 2D 中运行，或只编码 3D 位置而不含朝向，缺乏空中/水下导航所需的 4 自由度表征；(2) 视觉前端仍较简单（如 RatSLAM 的 1D 强度扫描线在复杂环境中只能产生约 5 个模板）；(3) IMU 集成缺失或临时拼凑，缺少生物系统中观察到的有原则的前庭-视觉融合。为弥补这些缺口，我们实现了具有 FCC 晶格结构的 3D 网格细胞与多层头方向细胞以实现完整的 4 自由度空间表征，集成了一条将模板判别力提升 192 倍以上的双流视觉处理流水线，并采用受生物启发的互补滤波进行前庭-视觉整合。

C. 基于学习的视觉处理

深度学习为视觉地点识别提供了强有力工具。Arandjelovic 等人提出了 NetVLAD [14]，引入可微 VLAD 层实现端到端地点识别训练。Goodale 与 Milner [29] 及 Mishkin 等人 [30] 建立了生物视觉双流理论：腹侧通路（V1→V4→IT）处理物体身份与场景识别，而背侧通路（V1→MT→MST）处理空间关系与运动 [31], [32]。Vaswani 等人提出了 Transformer 架构 [33]，通过自注意力机制捕获长程依赖，使序列任务的有效时序建模成为可能。然而，基于学习的方法面临部署挑战：NetVLAD 需要大规模训练数据集（如含数百万图像的 Google Street View），且难以在无需重训的情况下泛化到新环境；标准 Transformer 的全自注意力对序列长度呈二次复杂度 $\mathcal{O}(N^2)$，限制了实时应用；学习得到的表征缺乏显式空间结构，妨碍可解释性与度量建图的集成。为克服这些局限，我们采用一种一次训练、零样本部署的方案，结合受生物腹侧/背侧通路启发的双流视觉处理与轻量特征增强机制——后者通过统计调制而非完整注意力矩阵捕获全局-局部交互。该设计将视觉模板判别力从 5（RatSLAM）提升到评估序列中最多的 964 个（提升 192 倍以上），同时保持实时性能（约 31 FPS）；其学习组件仅在仿真上训练一次，部署时无需按域重训。

D. 对比分析

表 I 从关键架构维度对比了代表性仿生 SLAM 框架。现有方案存在四个根本局限：(1) 多数框架在 2D 中运行（RatSLAM、BatSLAM），或只编码 3D 位置而不含朝向（NeuroSLAM），缺乏完整 4 自由度表征；(2) 视觉前端依赖简单基于强度的模板（如 RatSLAM 的 1-D 扫描线），对光照变化敏感且模板多样性有限；(3) IMU 集成要么缺失，要么依赖计算昂贵的紧耦合优化；(4) 用于特征增强的现代注意力机制仍与显式空间细胞表征脱节。NeuroLocMap 系统性地弥补了这些缺口：我们通过 3D 网格细胞（FCC 晶格）与多层头方向细胞实现 4 自由度空间表征；采用带 HART 启发的空间注意力与轻量全局-局部特征调制的双流视觉处理，实现 192 倍以上模板提升；通过受生物启发的互补滤波集成前庭-视觉信号；并将这些组件统一到显式空间细胞框架内，实现可解释导航。

III. 方法

A. 符号与约定

符号约定. 上标表示感官模态（^{vis}：视觉，^{imu}：惯性，^{f}：融合）或细胞类型（^{g}：网格细胞，^{h}：头方向细胞）。下标 t 表示时间。粗体大写字母表示矩阵或高维数组；粗体小写字母表示向量；花体表示集合。

尺度与深度组件符号. s 为连接度量单位与 VO 相对单位的全局单目尺度因子，以第 10 个 EKF 状态 $\log s$ 承载；s^* 为真值尺度（仅训练期使用）。$\hat{z}_t$ 为冻结的单目深度基础模型（DAv2）的度量深度图，g_θ 为轻量尺度校正头（第 III-E节）；$\boldsymbol{e}_t$ 为闭环线所消费的学习全局场景嵌入（第 III-F节）。

B. 框架架构与全局状态空间表述

本工作为机器人定位设计了一个多模态视觉-惯性信号处理系统，它由三个紧耦合的功能子系统组成：分层多尺度视觉特征算子、前庭-惯性传感器状态估计器、度量空间状态编码网络。与传统的基于 EKF 的松耦合框架不同，所提出的系统采用频域互补融合来解耦低频视觉观测噪声与高频惯性瞬态噪声，并通过连续吸引子空间网络更新全局度量状态以抑制长期轨迹漂移。

1) 全局离散状态空间模型: 为后续所有子模块推导提供统一的数学基础，我们首先定义 t 时刻系统的离散状态空间表示。

1) 多模态原始输入向量

$$\mathbf{U}_t = \left[I_t,\, \mathbf{a}_t^\top,\, \boldsymbol{\omega}_t^\top \right] \tag{1}$$

其中 I_t 表示采集的单目 RGB 图像；$\mathbf{a}_t$ 与 $\boldsymbol{\omega}_t$ 分别为加速度计线加速度与陀螺仪角速度测量值。

2) 核心 4 自由度全局位姿状态向量

$$\mathbf{X}_t = [x_t,\, y_t,\, z_t,\, \psi_t]^\top \in \mathbb{R}^3 \times \mathrm{SO}(2) \tag{2}$$

在该表述中，$(x_t, y_t, z_t) \in \mathbb{R}^3$ 表示全局 3D 平移坐标（单位：米），$\psi_t \in [-\pi, \pi)$ 表示水平偏航角（单位：弧度）。

3) 统一状态演化映射函数

$$\mathbf{X}_{t+1} = \mathcal{F}\big(\mathbf{X}_t,\, \mathbf{U}_t\big) \tag{3}$$

映射 $\mathcal{F}(\cdot)$ 封装了完整的前向流水线，包括多尺度视觉特征提取、惯性运动计算、频域多模态融合与空间网络路径积分。$\mathcal{F}(\cdot)$ 的详细数学分解将在 3.3 节（视觉-前庭处理）与 3.4 节（空间编码网络）中给出。

如图 1 所示，端到端数据流水线由五个顺序耦合的模块组成：1. 分层双流视觉前端：构建并行的腹侧/背侧支路，分别独立生成场景描述子并计算逐像素自运动，消除识别与跟踪任务间的相互干扰。2. 前庭 IMU 处理模块：从原始惯性数据中推导高频瞬态运动信号，无需迭代式在线偏置标定。3. 互补融合单元：采用一阶 IIR 滤波器分离低频视觉漂移与高频惯性噪声，输出平滑的平移与旋转运动学量。4. 度量空间编码网络：使用融合运动线索更新分布式空间细胞状态，并通过视觉模板锚定约束抑制积分漂移。5. 拓扑经验图：记录历史视觉描述子与空间细胞快照，在检测到闭环时执行一次全局图松弛，以保证全局一致的度量位姿。

在这条五模块流水线之上，部署系统额外增加两个作用于融合估计（而非原始传感流）的高层校正：单目尺度恢复支路（第 III-E节），用冻结深度基础模型之上的轻量、一次训练头驱动 EKF 的尺度状态；以及基于学习嵌入的闭环线（第 III-F节），在经校验的重访处重新锚定轨迹。两者均仅在仿真数据上训练一次、部署时冻结——与基线的运动学尺度可观性形成对比，后者只会停在 VO 相对尺度、恢复不了绝对尺度。二者共同把跟踪核从一个 up-to-scale 的 VIO 估计器升级为实验中所评估的度量尺度系统。

C. 感官处理与融合

感官处理模块从视觉与惯性模态中提取自运动线索，然后通过互补滤波进行融合。

视觉前端. 视觉前端实现了受灵长类视觉皮层分层架构启发的生物学合理处理流水线，将原始 RGB 图像转化为适合地点识别与运动估计的紧凑场景描述子。

分层特征提取. 给定 RGB 图像 $I_t \in \mathbb{R}^{H \times W \times 3}$，我们定义一组模仿从视网膜到颞下皮层各处理阶段的算子。

阶段 1：视网膜与 LGN 处理. 初始预处理模拟视网膜与外侧膝状体（LGN）的早期视觉处理：

$$\text{亮度通道：} \quad Y_t = \mathcal{G}(I_t) = 0.299R + 0.587G + 0.114B \tag{4}$$

$$\text{局部对比度增强：} \quad U_t = \mathcal{C}_\lambda(Y_t), \quad \lambda = 0.02 \tag{5}$$

$$\text{感受野模拟：} \quad V_t = U_t * \mathcal{K}_\sigma, \quad \sigma = 0.5 \tag{6}$$

其中 $\mathcal{G}$ 为灰度转换算子，$\mathcal{C}_\lambda$ 为限幅对比度自适应直方图均衡（CLAHE），限幅为 λ；$\mathcal{K}_\sigma$ 为标准差 σ 的高斯核。CLAHE 在自适应增强局部对比度的同时防止噪声被过度放大，模仿视网膜神经节细胞的中心-周围拮抗组织结构。

TABLE I
仿生导航框架对比

框架	自由度	空间细胞	融合方法	视觉处理	闭环	时序模型
RatSLAM [26]	2D	PC+HDC	视觉	扫描线	经验	-
BatSLAM [27]	2D	PC+HDC	声呐	回声	经验	-
NeuroSLAM	3D	3D-GC	视觉	CNN	经验	LSTM
NeuroLocMap（本文）	**4D**	**3D-GC+M-HDC**	**互补**	**双流 +HART**	**经验**	**Trans.**

缩写: PC: 位置细胞; HDC: 头方向细胞; GC: 网格细胞; M-HDC: 多层头方向细胞; 经验: 经验地图; 互补: 互补滤波; Trans.: 受 Transformer 启发的时序建模; 视觉: 仅视觉; 双流 +HART: 带 HART 启发空间注意力的双流（腹侧/背侧）视觉处理。
注: 我们的特征增强使用全局统计调制（$\mathcal{O}(N)$ 复杂度）近似自注意力效果，而非完整 Query-Key-Value 运算（$\mathcal{O}(N^2)$），从而无需训练即可实现实时性能。

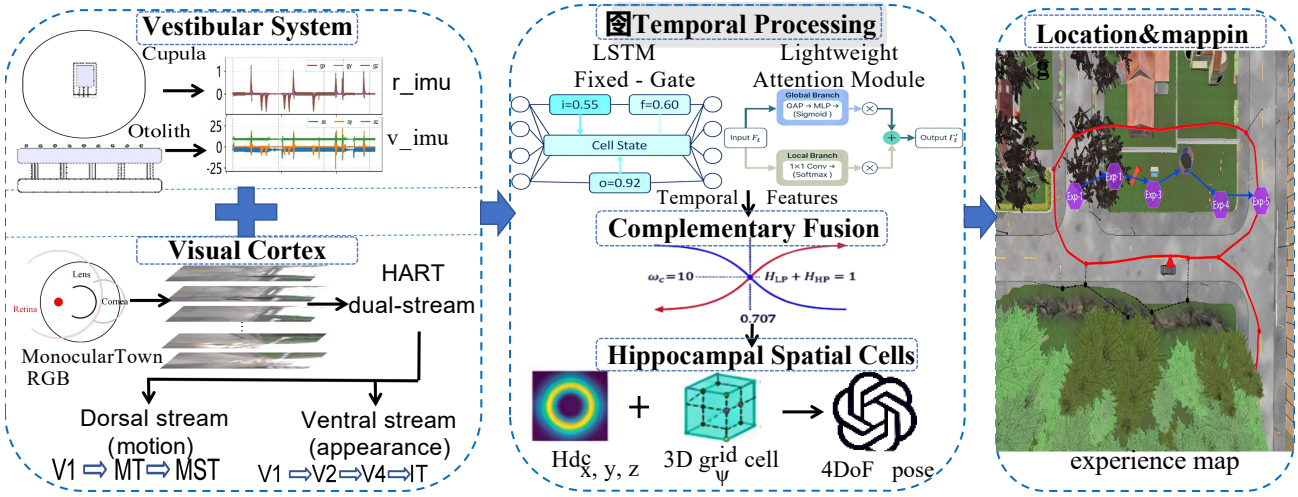


Fig. 1. 所提出的多模态视觉-惯性框架的自包含端到端数据流。原始输入为单目 RGB 图像与 IMU 测量值。视觉模块将信号分为场景识别与运动估计两支路；前庭模块输出高频惯性运动。两种模态通过频域互补滤波融合。融合后的运动学驱动空间网络更新统一定义于式 (2) 的 4 自由度全局状态 $\mathbf{X}_t$。经验图模块执行闭环松弛以消除长期轨迹漂移。所有子模块共享本小节提出的标准化状态空间变量。

阶段 2：初级视觉皮层（V1-V4）处理. 中层处理对表征进行归一化与标准化：

$$\textbf{动态范围归一化：}\quad \tilde{V}_t = \frac{V_t - \min(V_t)}{\max(V_t) - \min(V_t)} \tag{7}$$

$$\textbf{空间标准化：}\quad Z_t = \mathcal{D}(\tilde{V}_t) \in \mathbb{R}^{64\times 64} \tag{8}$$

$$\textbf{局部均值减去：}\quad Z_t(i,j) \leftarrow Z_t(i,j) - \frac{1}{64}\sum_{k=1}^{64} Z_t(i,k) \tag{9}$$

其中 $\mathcal{D}$ 为下采样算子（双线性插值）。按行减去均值可去除全局强度变化同时保留局部空间结构，类似于 V1 与 V2 中的除性归一化。

阶段 3：颞下（IT）表征. 最终表征为紧凑的向量化描述子：

$$\boldsymbol{\phi}_t = \mathrm{vec}(Z_t) \in \mathbb{R}^{4096} \tag{10}$$

其中 $\mathrm{vec}(\cdot)$ 表示将二维特征图映射为一维描述子的向量化算子，$\boldsymbol{\phi}_t$ 为时间戳 t 处的整体场景特征向量。该 $64 \times 64 = 4096$ 维特征向量作为整体场景描述子，类似于 IT 皮层中视图选择、位置不变的表征。

视觉模板匹配与地点识别. 地点识别通过基于余弦相似度的模板匹配实现，其鲁棒性优于绝对差之和（SAD）等基于强度的度量：

$$d_{\cos}(\boldsymbol{\phi}_t, \boldsymbol{\phi}_i) = 1 - \frac{\boldsymbol{\phi}_t^\top \boldsymbol{\phi}_i}{\|\boldsymbol{\phi}_t\|\,\|\boldsymbol{\phi}_i\|} \tag{11}$$

当当前场景与所有现有模板均足够不同时，创建新的视觉模板（VT）：

$$\textbf{若 } \min_{i\in\mathcal{VT}} d_{\cos}(\boldsymbol{\phi}_t, \boldsymbol{\phi}_i) > \tau_{vt} \textbf{ 则创建新 VT},\quad \tau_{vt} = 0.08 \tag{12}$$

阈值 $\tau_{vt} = 0.08$ 显著低于传统取值（OpenRatSLAM 中的 0.15），使相似场景间的判别更精细。实验验证表明，这可使模板数量增加最多 39 倍（城市环境中从 5 个增至 195 个），提供更丰富的地点表征。

双流架构与受生物启发的时序建模. 在上述分层特征提取的基础上，我们的视觉处理融入了两项关键的受生物启发创新：(1) 模仿腹侧/背侧通路的双流架构；(2) 无需训练数据、用于时序一致性的固定门 LSTM。

双流视觉处理. 遵循生物视觉双流理论 [29], [30]，我们从 V1 输出显式建模两条并行处理通路：

背侧通路（“where”通路，V1→MT→MST）：通过基于梯度的特征处理空间位置与运动信息：

$$\mathbf{F}_t^{\mathbf{dorsal}} = 0.6 \cdot \|\nabla Z_t\| + 0.4 \cdot Z_t \tag{13}$$

其中 $\|\nabla Z_t\|$ 为通过 Sobel 算子计算的梯度幅值，捕获边缘方向与运动方向，类似于 MT/MST 神经元。

腹侧通路（“what”通路，V1→V4→IT）：通过纹理与对比度处理物体身份与场景特征：

$$\mathbf{F}_t^{\mathbf{ventral}} = 0.4 \cdot Z_t + 0.3 \cdot \sigma_{\mathbf{local}}(Z_t) + 0.3 \cdot \mathcal{C}_\lambda(Z_t) \tag{14}$$

其中 $\sigma_{\mathbf{local}}$ 计算局部标准差（纹理特征），$\mathcal{C}_\lambda$ 提供对比度增强，模仿 V4 对复杂特征的选择性与 IT 的不变物体表征。

随后，两条支路通过一种轻量全局-局部特征调制机制（详见第 II-C 节）进行集成，该机制使用全局统计量而非完整 Query-Key-Value 运算来近似自注意力效果，保持 $\mathcal{O}(N)$ 复杂度以满足实时性能。

用于零样本时序建模的固定门 LSTM. 与需要在领域特定数据集上大量训练的传统数据驱动 LSTM 不同，我们的时序模块采用人工调定的固定门值，灵感来自生物学前庭-视觉整合原理 [19], [20]：

$$\textbf{输入门: } i_t = 0.55 \quad \textbf{（控制新信息摄入）} \tag{15}$$

$$\textbf{遗忘门: } f_t = 0.60 \quad \textbf{（保留 60\% 历史上下文）} \tag{16}$$

$$\textbf{输出门: } o_t = 0.92 \quad \textbf{（强调当前感知）} \tag{17}$$

其中 i_t、f_t、o_t 分别为受生物启发的 LSTM 模块的固定输入门、遗忘门、输出门。

该设计为 SLAM 应用提供了三个关键优势：

(1) 零样本部署能力：无需训练数据，可立即部署到新环境。这对 SLAM 至关重要，因为每个环境都有独特的视觉特性，且收集有代表性的训练数据并不可行。我们在六个多样化场景（城市、高速公路、室内）上不做任何环境特定调优的验证，展示了其鲁棒的泛化能力。

(2) 生物学可解释性：门值反映了神经科学中经实证验证的原则。遗忘门（$f_t = 0.6$）实现了与海马重放动力学一致的短期空间记忆保持，其中近期经验被优先保留用于路径积分。高输出门（$o_t = 0.92$）优先处理当前感觉输入，模仿前庭系统对即时自运动线索在平衡与导航中的强调。中等输入门（$i_t = 0.55$）在新奇检测与稳定性之间取得平衡。

(3) 计算效率：消除了训练开销（无反向传播、无梯度计算），同时保持实时性能（约 31 FPS）。固定门可直接在硬件（如 FPGA、神经形态芯片）上实现，无需权重存储或更新逻辑，使其能在资源受限平台上部署。

LSTM 按序处理融合后的背侧-腹侧特征，跨时间步维持隐藏状态 $\mathbf{H}_t$ 与细胞状态 $\mathbf{C}_t$：

$$\mathbf{C}_t = f_t \odot \mathbf{C}_{t-1} + i_t \odot \tanh(\mathbf{F}_t^{\mathbf{fused}}) \tag{18}$$

$$\mathbf{H}_t = o_t \odot \tanh(\mathbf{C}_t) \tag{19}$$

其中 $\odot$ 表示逐元素 Hadamard 积，$\mathbf{C}_t$ 为 LSTM 细胞状态，$\mathbf{H}_t$ 为时序隐藏状态，$\mathbf{F}_t^{\mathbf{fused}}$ 集成了腹侧与背侧视觉特征。

与基于学习方法对比. 第 IV 节表明，我们的固定门 LSTM 取得了与 NeuroSLAM 学习得到的 LSTM 相当或更优的性能（RMSE 改善 55%），同时提供零样本部署能力。这验证了：当底层任务结构与生物机制一致时，有原则的受生物启发设计可以匹配甚至超越数据驱动学习——在本例中即是空间导航，生物系统已在数百万年的进化中形成高度优化的解决方案。

视觉运动提取. 除场景识别外，视觉前端还从光流中提取自运动线索，模仿 MST（内侧上颞区）的背侧通路处理。

特征跟踪与光流计算. 设 $\mathbf{K} \in \mathbb{R}^{3\times3}$ 为相机内参矩阵。我们在相邻帧间跟踪 N 个特征点 $\mathbf{p}_i^t \in \mathbb{R}^2$（如使用 KLT 跟踪）。将跟踪点归一化到相机坐标：

$$\tilde{\mathbf{q}}_i^t = \mathbf{K}^{-1} \begin{bmatrix} \mathbf{p}_i^t \\ 1 \end{bmatrix}, \qquad \mathbf{q}_i^t = \pi(\tilde{\mathbf{q}}_i^t) = \frac{1}{\tilde{q}_{i,3}^t} \begin{bmatrix} \tilde{q}_{i,1}^t \\ \tilde{q}_{i,2}^t \end{bmatrix} \tag{20}$$

其中 π 为透视投影。计算像平面光流：

$$\mathbf{f}_i = \mathbf{q}_i^t - \mathbf{q}_i^{t-1}, \quad \mathbf{q}_i \equiv \mathbf{q}_i^{t-1} \tag{21}$$

旋转估计. 对帧间小旋转，归一化点 $\mathbf{q} = (x, y)$ 处偏航引起的流为 $\Delta t\, r\, [-y,\, x]^\top$。我们用加权最小二乘估计视觉偏航角速度：

$$r_t^{\text{vis}} = \frac{\sum_{i=1}^N w_i (x_i f_{i,y} - y_i f_{i,x})}{\Delta t \sum_{i=1}^N w_i (x_i^2 + y_i^2)} \tag{22}$$

其中 w_i 为 Huber 鲁棒权重以抑制离群特征点，N 为跟踪特征总数，r_t^{vis} 为视觉估计的偏航角速度。

平移估计. 去除旋转分量以获得平移主导的残余光流：

$$\mathbf{f}_i^\perp = \mathbf{f}_i - \Delta t\, r_t^{\text{vis}} \begin{bmatrix} -y_i \\ x_i \end{bmatrix} \tag{23}$$

假设存在主导地面平面，内点的逆深度为 $\lambda_i \approx 1/Z_g$，则平移流模型为：

$$\mathbf{f}_i^\perp \approx \Delta t\, \lambda_i \underbrace{\begin{bmatrix} -1 & 0 & x_i \\ 0 & -1 & y_i \end{bmatrix}}_{\mathbf{A}_i} \mathbf{v}_t^{\text{vis}}, \quad \mathbf{v}_t^{\text{vis}} = (v_x^{\text{vis}}, v_y^{\text{vis}}, v_z^{\text{vis}})^\top \tag{24}$$

带鲁棒权重 w_i 的加权最小二乘解为：

$$\bar{\mathbf{v}}_t^{\text{vis}} = \Big(\sum_i w_i \, (\Delta t\, \lambda_i)^2 \, \mathbf{A}_i^\top \mathbf{A}_i \Big)^{-1} \sum_i w_i \, (\Delta t\, \lambda_i) \, \mathbf{A}_i^\top \mathbf{f}_i^\perp \tag{25}$$

最终视觉里程计速度引入尺度因子 κ_t：

$$\mathbf{v}_t^{\text{vis}} = \kappa_t \, \bar{\mathbf{v}}_t^{\text{vis}} \tag{26}$$

其中 λ_i 为特征点 i 的逆深度，矩阵 $\mathbf{A}_i$ 为几何投影矩阵，$\bar{\mathbf{v}}_t^{\text{vis}}$ 为从光流解出的原始平移速度，κ_t 为视觉里程计的在线尺度校正因子。

除运动流外,背侧前端还提供像素级度量深度场 $\hat{z}_t$(冻结 DAv2 主干）与学习场景嵌入 $\boldsymbol{e}_t$，供两个高层校正消费（第 III-E节）；深度估计与场景识别与上述速度估计保持解耦。

前庭前端. 前庭前端处理惯性测量值以提取自运动线索，类比哺乳动物的前庭系统。前庭器官由半规管（角速度）与耳石器（线加速度）组成。

角速度提取. 由陀螺仪测量值 $\mathrm{g}_t \in \mathbb{R}^3$（IMU 坐标系），我们直接使用 z 轴陀螺而不做在线偏置去除，并按实现转换为度/秒。在平面约束下的 4 自由度定位-建图中，偏航（方位角）角速度近似为

$$r_t \approx \mathbf{e}_z^\top \boldsymbol{\omega}_t^g, \quad \mathbf{e}_z = (0, 0, 1)^\top. \tag{27}$$

其中 $\boldsymbol{\omega}_t^g$ 为 IMU 测得的原始陀螺角速度向量，$\mathbf{e}_z$ 为单位竖直基向量。这对应水平半规管线索，足以满足我们与视觉的互补融合需求。

线加速度使用（简化）. 我们采用与代码库一致的轻量近似：使用加速度计幅值与 z 轴读数，减去常数重力 $g{=}9.81$，在帧间隔 Δt 上推导指示性的平移与垂向速度分量：

$$v_{trans}^{\text{imu}}(t) \approx \max\big(0, (\|\mathbf{a}_t\| - g)\, \Delta t\, k_t\big), \tag{28}$$

$$v_z^{\text{imu}}(t) \approx (a_{t,z} - g)\, \Delta t\, k_z, \tag{29}$$

其中 $g = 9.81\,\mathrm{m/s^2}$ 为重力加速度，k_t, k_z 为与实现常数匹配的常值缩放增益，Δt 为帧采样间隔。这避免了显式偏置/重力向量估计，同时提供随后通过互补融合与视觉里程计结合的高频运动线索。

偏置估计. 基线实现不进行在线偏置或重力向量估计。更先进的偏置/重力补偿可作为未来工作集成，但对于此处报告的互补融合结果并非必需。

互补 IMU-视觉融合. 视觉与惯性模态提供互补信息：视觉里程计提供精确的低频位置估计但长期会漂移，而 IMU 积分提供可靠的高频运动线索但会累积偏置漂移。互补滤波利用这种频域分离，无需复杂非线性优化或扩展卡尔曼滤波即可实现鲁棒融合。图 2 展示了该互补融合策略的频域特性及其在前庭-视觉整合中的生物学对应。

滤波器设计. 设 $\mathcal{L}_\tau$ 表示时间常数为 τ 的低通滤波器，$\mathcal{H}_\tau$ 表示满足 $\mathcal{L}_\tau + \mathcal{H}_\tau = \mathrm{Id}$（单位算子）的互补高通滤波器。融合后的速度与偏航角速度为：

$$\textbf{低通: } L_t = \alpha L_{t-1} + (1-\alpha) x_t, \quad L_0 = 0 \tag{30}$$

$$\textbf{高通: } H_t = x_t - L_t \tag{31}$$

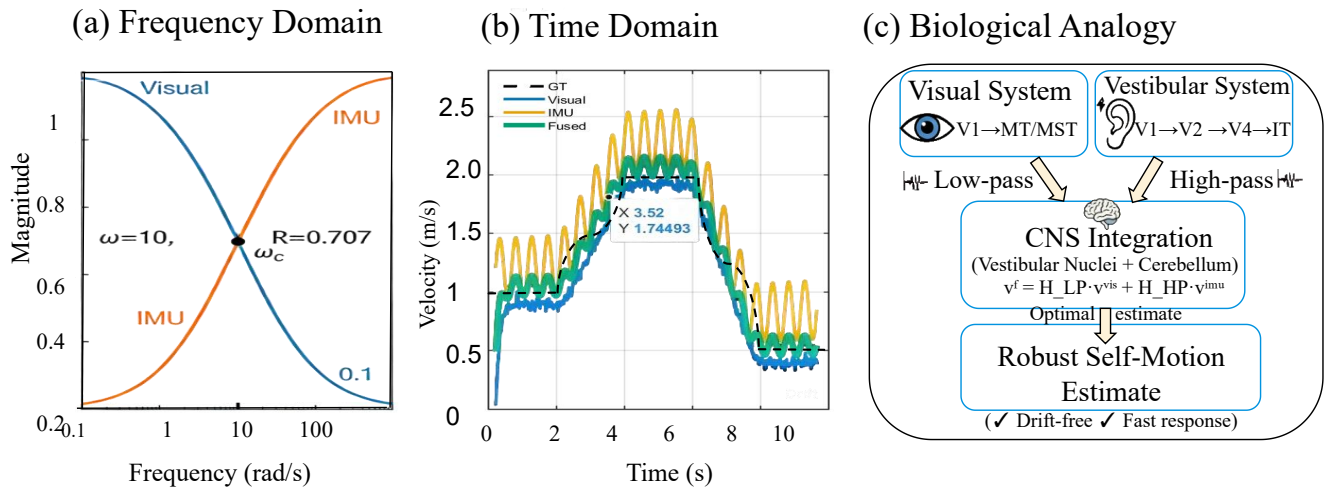


Fig. 2. 互补 IMU-视觉融合架构。(a) 展示互补滤波特性的频域分析。(b) 时域信号对比。(c) 中枢神经系统中前庭-视觉整合的生物学类比。

其中 α 为 IIR 滤波器遗忘因子，L_t 存储低频平滑信号，H_t 存储残余高频信号分量。

生物学类比. 该融合策略镜像了前庭核与后顶叶皮层（7a 区）中的多感官整合，视觉与前庭信号在此结合以估计自运动。这些区域的神经元表现出视觉与前庭调制的加权组合，且权重随信号可靠性动态变化——类似于我们的固定权重参数 η 与 η_r。

离散时间实现. 在采样间隔 Δt 下，我们实现一阶 IIR（无限脉冲响应）滤波器。选取遗忘因子 $\alpha = \exp(-\Delta t/\tau)$ 与 $\alpha_r = \exp(-\Delta t/\tau_r)$。对任意输入序列 x_t，定义：

$$\text{低通：}\quad L_t = \alpha L_{t-1} + (1-\alpha)x_t, \quad L_0 = 0 \tag{32}$$

$$\text{高通：}\quad H_t = x_t - L_t \tag{33}$$

则融合线索计算如下：

$$\mathbf{v}_t^{\mathrm{f}} = (1-\eta)\, L_t^{\mathrm{vis}} + \eta\, H_t^{\mathrm{imu}} \tag{34}$$

$$r_t^{\mathrm{f}} = (1-\eta_r)\, L_t^{r,vis} + \eta_r\, H_t^{r} \tag{35}$$

其中 L_t^{vis} 与 H_t^{imu} 分别表示低通滤波后的视觉速度与高通滤波后的 IMU 速度，偏航角速度同理。

频域传递函数. 在 $s = j\omega$（频率变量）的拉普拉斯域中，一阶低通与高通滤波器的传递函数为：

$$H_{LP}(s) = \frac{1}{1+\tau s} = \frac{1/\tau}{s+1/\tau}, \tag{36}$$

$$H_{HP}(s) = \frac{\tau s}{1+\tau s} = \frac{s}{s+1/\tau}, \tag{37}$$

满足 $H_{LP}(s) + H_{HP}(s) = 1$（全频域单位增益）。截止频率 $\omega_c = 1/\tau$ 分隔低频与高频区域：当 $\omega \ll \omega_c$ 时，$|H_{LP}| \approx 1$ 且 $|H_{HP}| \approx 0$，视觉通路占主导（无漂移、动力学较慢）；而当 $\omega \gg \omega_c$ 时，$|H_{LP}| \approx 0$ 且 $|H_{HP}| \approx 1$，IMU 线索占主导（快但漂移）。

取 $\tau = 0.1$ s 时，截止频率为 $\omega_c = 10$ rad/s（≈ 1.6 Hz），确保 IMU 处理高频运动（>2 Hz，如振动、快速转弯），而视觉校正低频漂移（<1 Hz）。这模仿了生物学前庭-视觉整合，其中前庭器官响应 0.1-10 Hz 的频率，而低于 0.5 Hz 时视觉运动感知占主导 [19]。

计算效率. 该实现每个信号只需两个状态变量（当前低通滤波器状态 L_t 与前值 L_{t-1}），仅涉及简单的标量乘法与加法。每次更新计算代价为 $\mathcal{O}(1)$，适合实时嵌入式实现——这与紧耦合视觉-惯性里程计的扩展卡尔曼滤波所需的 $\mathcal{O}(n^3)$ 矩阵求逆形成鲜明对比。

自适应加权. 虽然基线实现使用固定融合权重 η 与 η_r，但该框架可自然扩展到基于信号可靠性的自适应加权。例如，在激烈机动或光照快速变化时，视觉里程计可能不可靠，应增加对 IMU 的依赖（$\eta \to 1$）。反之，在 IMU 积分累积偏置的慢速运动中，视觉里程计应占主导（$\eta \to 0$）。自适应方案可实现为：

$$\eta_t = f(\sigma_t^{\mathrm{vis}}, \sigma_t^{\mathrm{imu}}), \quad \text{例如} \quad \eta_t = \frac{\sigma_t^{\mathrm{vis}}}{\sigma_t^{\mathrm{vis}} + \sigma_t^{\mathrm{imu}}} \tag{38}$$

其中 σ_t^{vis} 与 σ_t^{imu} 为视觉与惯性测量的实时不确定性估计，η_t 为时变融合权重。

此外，式 (26) 中的视觉里程计尺度因子 κ_t 可以自适应，以维持视觉与惯性速度幅值间的一致性：

$$\kappa_{t+1} = \kappa_t \cdot \left(1 + \beta \frac{\|\mathbf{v}_t^{\mathrm{imu}}\| - \|\kappa_t \bar{\mathbf{v}}_t^{\mathrm{vis}}\|}{\|\kappa_t \bar{\mathbf{v}}_t^{\mathrm{vis}}\|}\right) \tag{39}$$

其中 $\beta \ll 1$ 为在线视觉里程计尺度校正的小自适应增益（如 $\beta = 0.01$）。该在线尺度自适应可补偿所设地面平面深度或相机标定不精确引起的系统误差。

D. 神经空间表征

空间表征模块通过结合式位姿细胞（conjunctive pose cells）使用受生物启发的神经坐标系编码机器人的 4 自由度位姿。3D 位置 (x, y, z) 由使用 3D 连续吸引子网络（MD-CAN）的网格细胞表示，而朝向 ψ（偏航）由多层头方向细胞编码。这些表征通过吸引子动力学实现稳定、容噪的路径积分。

3D 网格细胞网络. 3D 网格细胞网络模仿哺乳动物大脑中的 3D 空间神经表征，表现出规则的 3D 晶格模式（面心立方，

FCC），编码位置并为路径积分提供普适度量。受蝙蝠 3D 网格细胞发现 [6] 与六角形网格结构理论模型 [4] 的启发，我们的实现在保持关键生物学性质（多尺度表征、度量路径积分、噪声鲁棒性）的同时，将 2D 连续吸引子网络扩展到完整 3D 空间。

网络架构. 3D 网格细胞网络是维度为 $N_x \times N_y \times N_z$（典型取 $N_x = N_y = N_z = 61$）的 3D 多尺度连续吸引子网络（MD-CAN）。网络活动 $\mathbf{A}^{\mathrm{g}}_t \in \mathbb{R}^{N_x \times N_y \times N_z}$ 表示机器人 3D 位置 (x_t, y_t, z_t) 的分布式群体编码，其中每个细胞 (i, j, k) 调谐于环境中的某个偏好空间位置。活动形成以当前位置为中心局域化的“凸起”（或活动包），类似于啮齿动物内嗅皮层记录中观察到的活动凸起。

网络拓扑采用环面卷绕的周期性边界条件，实现无界空间表征。细胞间连接遵循面心立方（FCC）晶格——3D 中最致密的球堆积——以最少神经元提供最优空间覆盖。在 FCC 结构中，每个细胞有 12 个最近邻（2D 六角形网格中为 6），从而得到各向同性方向敏感度的高效 3D 路径积分。

图 3 示意性地展示了：(a) 位置 (x, y, z) 处的 3D 活动凸起，以等值面表示以可视化局域化兴奋；(b) FCC 晶格投影到 2D 平面，展示由层间偏移排布产生的特征六角形模式，不同高度层（以颜色标示）平移半个晶格常数以实现最优堆积；(c) 集成位置与朝向表征的完整 4 自由度编码流水线。

连续吸引子动力学. 网络通过三个关键机制维持局域化的活动“凸起”：

(1) 局域兴奋. 细胞按高斯连接核兴奋其邻居。采用可分离核

$$\mathcal{K}^{\mathrm{g}}_{a,b,c} = \mathcal{N}(a; 0, \sigma_x)\mathcal{N}(b; 0, \sigma_y)\mathcal{N}(c; 0, \sigma_z) \tag{40}$$

其中 $\mathcal{N}(\cdot; \mu, \sigma)$ 表示一维高斯分布，$\sigma_x, \sigma_y, \sigma_z$ 为三轴上的空间核宽度。兴奋性更新为：

$$\Delta A^{\mathrm{g}}_{i,j,k} = \sum_{p,q,r} A^{\mathrm{g}}_{p,q,r}\, \mathcal{K}^{\mathrm{g}}_{\langle i-p\rangle_{N_x}, \langle j-q\rangle_{N_y}, \langle k-r\rangle_{N_z}} \tag{41}$$

其中 $\langle\cdot\rangle_N$ 表示周期性边界条件下的模 N 卷绕。典型参数为 $\sigma_x = \sigma_y = \sigma_z = 5$ 个细胞。

(2) 全局抑制与归一化. 均匀全局抑制减去平均活动，整流与归一化维持单一稳定凸起：

$$A^{\mathrm{g}}_{i,j,k} \leftarrow \left[A^{\mathrm{g}}_{i,j,k} + \Delta A^{\mathrm{g}}_{i,j,k} - \lambda\, \bar{A}^{\mathrm{g}}\right]_+, \quad \bar{A}^{\mathrm{g}} = \frac{1}{N_x N_y N_z} \sum_{p,q,r} A^{\mathrm{g}}_{p,q,r} \tag{42}$$

其中 $[\cdot]_+ = \max(0, \cdot)$ 为整流，λ 控制抑制强度（典型 $\lambda = 1.0$）。抑制之后，活动做 L_1 归一化：

$$A^{\mathrm{g}} \leftarrow \frac{A^{\mathrm{g}}}{\|A^{\mathrm{g}}\|_1} = \frac{A^{\mathrm{g}}}{\sum_{i,j,k} |A^{\mathrm{g}}_{i,j,k}|} \tag{43}$$

该归一化确保活动模式具有单位总质量，使读出（质心）对整体活动幅度不敏感。

(3) 路径积分. 活动凸起按融合速度线索 $\mathbf{v}^{\mathrm{f}}_t = (v^f_x, v^f_y, v^f_z)$ 移动。索引移动量计算为：

$$(\Delta i, \Delta j, \Delta k) = \left(\lfloor \gamma_x v^f_x \Delta t \rfloor,\ \lfloor \gamma_y v^f_y \Delta t \rfloor,\ \lfloor \gamma_z v^f_z \Delta t \rfloor\right) \tag{44}$$

其中 $\gamma_x, \gamma_y, \gamma_z$ 为度量-索引增益因子，将物理速度转换为网络网格移动。

$$A^{\mathrm{g}}_{i,j,k} \leftarrow A^{\mathrm{g}}_{\langle i-\Delta i\rangle_{N_x}, \langle j-\Delta j\rangle_{N_y}, \langle k-\Delta k\rangle_{N_z}} \tag{45}$$

该离散移动操作在环面网络拓扑上高效实现了路径积分。

视觉锚定与漂移校正. 纯路径积分会随时间累积漂移。为防止误差无界增长，网格细胞活动通过学习到的关联锚定到视觉地标。设 $\Xi_{m,i,j,k}$ 存储视觉模板 m 与网格细胞 (i, j, k) 之间的关联强度。对每个激活的视觉模板 $m \in \mathcal{S}_{active}$，更新关联并注入校正活动：

$$\textbf{Hebbian 学习: } \Xi^{t+1}_{m,i,j,k} = \max\left(\eta\, VT_m\, A^{\mathrm{g}}_{i,j,k},\ \Xi^{t}_{m,i,j,k}\right) \tag{46}$$

$$\textbf{校正注入: } \Delta A^{\mathrm{g}}_{i,j,k} \mathrel{+}= \frac{\rho}{|\mathcal{S}_{active}|} \sum_{m \in \mathcal{S}_{active}} VT_m\, \Xi_{m,i,j,k} \tag{47}$$

其中 η 为 Hebbian 学习率，ρ 为空间校正强度，$\mathcal{S}_{active}$ 为当前匹配的视觉模板集合。

多层头方向细胞. 多层头方向细胞（HDC）网络使用维度为 $N_\psi \times N_h$（方位角分箱 × 高度层）的 2D MD-CAN 表示机器人的朝向。不同高度层允许表示不同垂直位置处的朝向，支持朝向可能随高度变化的 3D 运行。

网络架构. 多层头方向网络的活动为 $\mathbf{A}^{\mathrm{h}} \in \mathbb{R}^{N_\psi \times N_h}$（典型取 $N_\psi = 360$ 个方位角分箱，$N_h = 5$ 个高度层）。每个细胞 (u, h) 调谐于方位角 $\theta_u = 2\pi u / N_\psi$ 与高度层 h。

吸引子动力学. 与网格细胞网络类似，HDC 网络采用局域兴奋、全局抑制与路径积分。采用高斯核 $\mathcal{K}^{\mathrm{h}}$：

$$\Delta A^{\mathrm{h}}_{\psi,h} = \sum_{u,v} A^{\mathrm{h}}_{u,v}\, \mathcal{K}^{\mathrm{h}}_{\langle\psi-u\rangle_{N_\psi}, \langle h-v\rangle_{N_h}} \tag{48}$$

随后进行抑制与归一化：

$$A^{\mathrm{h}} \leftarrow \frac{[A^{\mathrm{h}} + \Delta A^{\mathrm{h}} - \lambda_h\, \bar{A}^{\mathrm{h}}]_+}{\|A^{\mathrm{h}}\|_1} \tag{49}$$

路径积分按偏航角速度 r^f 与垂向速度 v^f_z 移动活动凸起：

$$\Delta\psi = \lfloor \gamma_\psi r^f \Delta t \rfloor, \quad \Delta h = \lfloor \gamma_h v^f_z \Delta t \rfloor \tag{50}$$

其中 γ_ψ 将角速度转换为方位角分箱，γ_h 将垂向速度映射为高度层移动量。

位姿读出. 度量位姿估计通过质心计算（群体向量解码）从空间细胞活动中解码得到：

$$\hat{\mathbf{p}}_t = (\hat{x}_t, \hat{y}_t, \hat{z}_t) = \frac{\sum_{i,j,k} \mathbf{c}_{i,j,k} A^{\mathrm{g}}_{i,j,k,t}}{\sum_{i,j,k} A^{\mathrm{g}}_{i,j,k,t}}, \quad \mathbf{c}_{i,j,k} = (x_i, y_j, z_k) \tag{51}$$

$$\hat{\psi}_t = \operatorname{atan2}\left(\sum_{u,h} A^{\mathrm{h}}_{u,h,t} \sin\theta_u, \sum_{u,h} A^{\mathrm{h}}_{u,h,t} \cos\theta_u\right), \quad \theta_u = 2\pi u / N_\psi \tag{52}$$

该解码天然处理朝向的环形拓扑（使用 atan2 避免角度回绕问题），并通过加权平均为位置提供亚分箱分辨率。

E. 单目尺度恢复支路

问题. EKF 第 10 个状态 $\log s$ 在线从转弯运动学收敛，但转弯运动学仅在转弯帧可观测（KITTI 07 上 294/1101 帧），且按构造只能恢复 *VO* 相对尺度——视觉帧与度量世界之间的绝对尺度无法仅从惯性运动恢复。单目度量深度网络提供了独立线索，但其零样本预测带场景相关偏置（初步研究表明原始深度尺度跨场景不可靠），因此原始深度不能直接作为尺度观测。我们不直接信任深度网络，而是学习一个轻量标定：把深度统计特征映射到真实全局尺度——仅在仿真上训练一次，部署时冻结。

结构. 对每帧 t，设 $\hat{z}_t$ 为冻结的单目深度基础模型（Depth-Anything-V2，户外头）预测的度量深度图。将其归纳为 8 维特征向量

$$\mathbf{f}_t = \left[\log \hat{s}^{\mathrm{dav2}}_t,\ \log d^{\mathrm{med}}_t,\ \log(d^{\mathrm{std}}_t + \epsilon),\ \log d^{\mathrm{p10}}_t,\ \log d^{\mathrm{p90}}_t,\ \log(\hat{s}^{\mathrm{inl}}_t + 1),\ f_x/W\right. \tag{53}$$

其中 $\hat{s}^{\mathrm{dav2}}_t$ 为窗口中值零样本深度尺度估计（帧间 VO 位移除以中值度量深度），$d^{\mathrm{med}}, d^{\mathrm{p10}}, d^{\mathrm{p90}}, d^{\mathrm{std}}$ 为度量深度的中值、分位数与标准差，$\hat{s}^{\mathrm{inl}}_t$ 为特征内点一致尺度，f_x/W 编码相机几何。每个特征经窗口中值平滑（W=50 区间）。尺度头 g_θ 为紧凑 MLP $8 \to 64 \to 64 \to 1$（ReLU，∼4.8k 参数），预测对数尺度

$$\hat{\ell}_t = g_\theta(\mathbf{f}_t) \ \approx\ \log s^*_t, \tag{54}$$

监督信号（仅训练期）为逐区间真值尺度

$$\ell^*_t = \log \frac{\|\mathbf{p}^*_t - \mathbf{p}^*_{t-1}\|}{\|\mathbf{p}_t - \mathbf{p}_{t-1}\|}, \tag{55}$$

其中 $\mathbf{p}^*$ 为真值度量位置（仿真中可得），$\mathbf{p}$ 为 VO 位置。

一次训练协议. 头在三个仿真城镇（Town05/03/07）上以 Adam（学习率 10^{-3}，权重衰减 10^{-3}）、标准化特征上的 MSE 损失与留出集（10%）早停训练；特征标准化随权重一起冻结。第四城镇（Town10HD）完全留出，且不见任何真实数据。训练

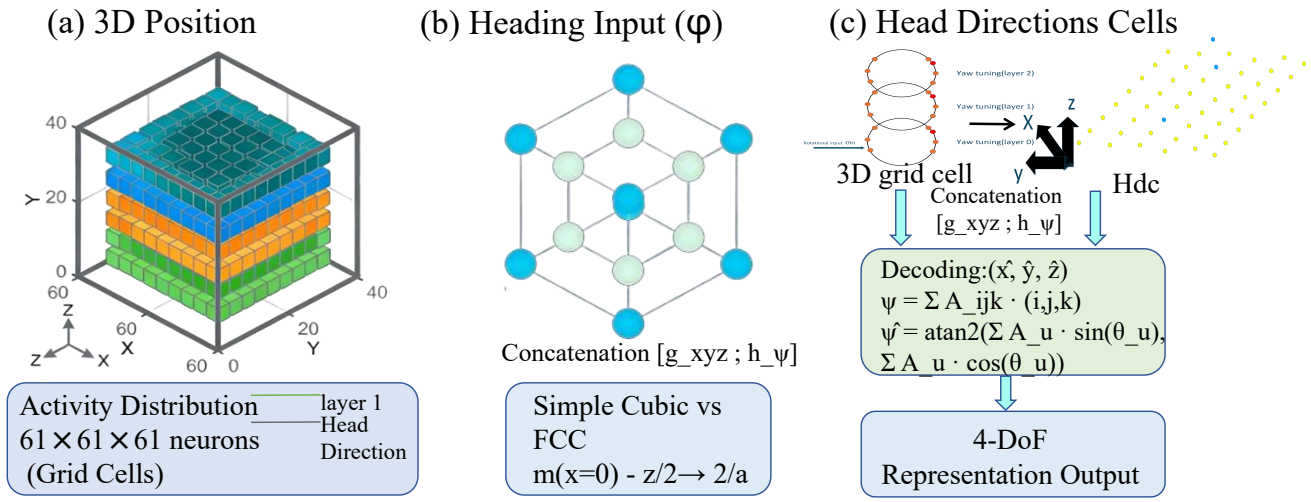


Fig. 3. 具有 FCC 晶格结构的 3D 网格细胞网络。(a) 通过分布式群体编码表示位置 (x, y, z) 的 3D 活动包。(b) 展示三层高度实现的致密 3D 堆积、呈现六角形网格模式的 FCC 晶格结构。(c) 结合位置与朝向表征的 4 自由度编码方案。

后全部参数冻结：部署时无逐序列标定、无在线自适应——头在每条测试序列上原样使用。

门控整合. 预测 $\hat{s}_t = \exp(g_\theta(\mathbf{f}_t))$ **作为对数域尺度支路观测进入 EKF：(i) 支路启用时替换** $\log s$ **的深度中值初值；(ii) 通过带对数域死区的卡方门控更新持续拉动尺度态；(iii) 启用时抑制运动学尺度观测，使两个尺度证据源不互相打架。该校正是刻意仅尺度的：只调整第 10 个状态并经它调整视觉速度观测——从不直接改写位置或朝向，因此错误的尺度预测会优雅退化而非污染融合轨迹。**

零样本行为与诚实边界. 在仿真域内，学到的映射跨场景泛化——包括留出城镇——并在全部五条评估序列上胜过普通最小二乘标定基线。然而跨 sim-to-real 边界时映射不迁移：在 KITTI 07 上头预测的尺度校正方向相反（轨迹实际需要 ≈ 1.8 **而预测** $s \approx 0.3$**），部署它反而劣化 EKF（补充材料第 S.1 节量化该失效）。因此本文所有真实世界结果均不带尺度支路运行——这是我们在实验中回到的诚实局限。头的计算开销可忽略：**$\sim$**4.8k 参数、每帧亚毫秒 CPU 推理，不在 31-FPS 关键路径上；冻结的深度主干异步评估并缓存。**

F. 经验地图与闭环

多层经验地图将 3D 空间经验表示为图结构，提供一种混合拓扑-度量表征，兼具离散基于地点的地图（拓扑鲁棒性、闭环）与连续度量表征（精确定位）的优点。

经验表征. 每个经验节点 $\mathcal{E}_i$ **编码一段独立的空间情节，包含激活的视觉模板与描述子** $(VT_i, \boldsymbol{\phi}_i \in \mathbb{R}^{4096})$**、同步的空间细胞编码** $\mathbf{P}_i^{gc} = \mathbf{A}_i^{\mathrm{g}} \in \mathbb{R}^{N_x \times N_y \times N_z}$ **与** $\mathbf{P}_i^{hdc} = \mathbf{A}_i^{\mathrm{h}} \in \mathbb{R}^{N_\psi \times N_h}$**、从这些活动解码出的度量位姿** (x_i, y_i, z_i, ψ_i)**，以及用于时序排序的时间戳** t_i**。这种丰富的多模态编码通过视觉匹配实现鲁棒的闭环检测，同时通过空间细胞编码保持度量信息。**

经验创建与连接. 随着机器人导航，当当前空间表征与所有现有经验都足够不同时，创建新经验。创建准则综合视觉与空间细胞相似度：

$$\begin{aligned} &\text{若 } d_{cos}(\boldsymbol{\phi}_t, \boldsymbol{\phi}_j) > \tau_{VT} \quad \text{对所有} j \in \mathcal{E} \\ &\quad \text{或} \|(\hat{x}_t, \hat{y}_t, \hat{z}_t) - (x_j, y_j, z_j)\| > d_{thresh} \text{ 则创建新经验} \end{aligned} \tag{56}$$

其中 $\tau_{VT} = 0.08$ **为视觉模板匹配阈值，** d_{thresh} **为空间距离阈值（典型 0.5 m）。**

相邻经验由编码相对位姿转移的有向边连接：

$$\mathbf{T}_{i \to i+1} = (\Delta x, \Delta y, \Delta z, \Delta\psi) = (x_{i+1} - x_i, y_{i+1} - y_i, z_{i+1} - z_i, \psi_{i+1} - \psi_i) \tag{57}$$

这些边构成经验地图图 $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ **的主要拓扑结构。**

闭环检测. 当当前视觉模板与某历史经验匹配超过最小时间间隔（以避免平凡闭环）时，检测到闭环：

$$\begin{aligned} &\text{若存在} j : d_{cos}(\boldsymbol{\phi}_t, \boldsymbol{\phi}_j) < \tau_{loop} \\ &\qquad |t - t_j| > T_{min} \text{ 则检测到闭环} \end{aligned} \tag{58}$$

其中 $\tau_{loop} = 0.05$ **（比模板创建阈值更严格，以减少误报），** $T_{min} = 50$ **帧（10 Hz 下约 5 秒）。**

检测到闭环后，向图中添加一条带位姿残差的闭环边：

$$\mathbf{T}_{loop} = (\hat{x}_t - x_j, \hat{y}_t - y_j, \hat{z}_t - z_j, \hat{\psi}_t - \psi_j) \tag{59}$$

该闭环约束通常违背图一致性（由于累积漂移），从而触发地图松弛。

地图松弛. 地图松弛将闭环误差分布到闭环路径上的所有经验，以最小化全局不一致。我们采用迭代松弛算法：

第 1 步：识别闭环路径. 给定从经验 j **到经验** t **的闭环边，识别沿路径的经验序列** $\mathcal{P} = \{j, j+1, \ldots, t-1, t\}$**。**

第 2 步：计算位姿残差. 沿闭环累积的位姿转移理想情况下应当闭合（回到原点）：

$$\mathbf{e}_{loop} = \sum_{k \in \mathcal{P}} \mathbf{T}_{k \to k+1} - \mathbf{T}_{loop} \tag{60}$$

其中 $\mathbf{e}_{loop}$ **为闭合轨迹周围的累积位姿漂移残差，** $\mathcal{P}$ **表示构成闭环的有序经验序列。**

第 3 步：分布校正. 将校正量按比例分布到闭环经验上：

$$\mathbf{T}_{k \to k+1} \leftarrow \mathbf{T}_{k \to k+1} - \frac{\mathbf{e}_{loop}}{|\mathcal{P}|} \tag{61}$$

该均匀分布假设漂移以恒定速率累积，是一个合理的一阶近似。

第 4 步：更新经验位姿. 通过对校正后的转移量积分，重新计算所有经验位姿：

$$(x_{k+1}, y_{k+1}, z_{k+1}, \psi_{k+1}) = (x_k, y_k, z_k, \psi_k) + \mathbf{T}_{k\to k+1} \tag{62}$$

第 5 步：重新锚定空间细胞. 将校正后的位姿 $(\hat{x}, \hat{y}, \hat{z}, \hat{\psi})_{corr}$ 通过在校正位置处重新初始化活动凸起，重新注入空间细胞网络。这从校正后的参考点“重置”路径积分，防止后续运行中误差累积。

该松弛过程迭代运行直至收敛或达到最大迭代次数，确保经验地图保持全局一致，同时保留局部度量精度。

部署闭环线：帧基候选. 所报告系统的闭环检测建立在帧而非经验节点之上：每帧由冻结 DINOv2-S 全局场景嵌入 $\mathbf{e}_t$ 描述，再经与尺度支路同一一次训练协议训练的细调头精炼（仅用仿真数据）。当前帧的候选匹配是历史帧 $j^* = \arg\max_j \cos(\mathbf{e}_t, \mathbf{e}_j)$，限制于 EKF 里程计弧长间隔超过 $\mathrm{arc}_{\min}$（50 m）的帧——排除了平凡的自匹配，同时保持对一切可信远历史的全局搜索。这一帧级候选阶段把闭环检测与经验节点生成解耦，为门链提供逐帧稠密证据。

四重门链. 候选须通过四个固定门（所有阈值在五场景上一次设定）方可成为被接受的闭环事件：

$$\mathrm{accept}(t, j^*) \iff \cos(\mathbf{e}_t, \mathbf{e}_{j^*}) \geq \tau \wedge \mathrm{streak}(t, j^*) \geq 15 \wedge |\Delta\psi_{tj^*}| \leq 60^\circ \tag{63}$$

另有全轨迹累计校正预算 $\sum_i \|\mathbf{c}_i\| \leq 35$ m，以及历史锚点去重（每帧历史至多锚定一次）。相似度门（$\tau = 0.94$）由五场景扫描标定：观测到的假候选得分 0.907–0.935，而强真实重访得分 ≥ 0.949。持续性门（≥ 15 个连续候选帧，± 10 容差）利用真实重访的结构性性质：车辆驶过同一条街会生成持续的高相似度帧串，而感知混叠只产生单帧或短突发尖峰——此门无尺度依赖，跨域原样迁移。朝向门（航向差 60°）容许同向与反向重访，同时拒绝几何上不可行的匹配。校正预算限制任何单次误接受的损害。该链刻意保守：KITTI 09 唯一的真环位于末尾两帧，串长至多 $2 < 15$，门正确拒绝——即使事后放行，误差也仅变化 -0.12 m——而朝向门拒绝了该序列上两个高相似但几何不一致的候选（补充材料第 S.3 节）。宁缺毋滥。

注入. 被接受的事件注入一次性平移校正 $\mathbf{c}_{tj^*}$（步长 $\beta = 1.0$），把当前段拉向匹配节点的地图位姿，把一条 link 边写入经验图，并将该事件交给下文的全 Sim(3) 重锚定算子；校正后的段随后进入上方的漂移场松弛。

分布式闭环漂移场. 每次重锚定事件（闭环或匹配到已有节点）都会重置增量航位推算状态，使原始输出轨迹在帧 f_i 处包含一个幅值为 $\mathbf{c}_i$ 的离散校正阶跃。这些阶跃累积成阶梯函数 $\mathbf{C}_{\mathrm{cum}}(f)$，其离散跳变是经验地图校正输出与滤波前端之间逐帧不一致的主要来源。受海马-内嗅系统中空间记忆慢速再巩固的启发，我们将每个阶跃松弛为连续漂移场。对每个幅值 $\|\mathbf{c}_i\| \leq C_{\max}$ 的重锚定脉冲，施加持续 W_i 帧的升余弦斜坡：

$$F_i(f) = \begin{cases} \frac{1}{2}\big(1 - \cos(\pi(f - f_i)/W_i)\big), & f_i \leq f < f_i + W_i \\ 1, & f \geq f_i + W_i \end{cases} \tag{64}$$

校正后的轨迹为

$$\hat{\mathbf{p}}(f) = \mathbf{p}_{\exp}(f) + \Big(\sum_i F_i(f)\,\mathbf{c}_i \;-\; \sum_{i:\, f_i \leq f} \mathbf{c}_i\Big), \tag{65}$$

即每次校正在斜坡结束后仍以保持值 $\mathbf{c}_i$ 持续生效，但其起始过程在 W_i 帧内被平滑，阶梯 $\mathbf{C}_{\mathrm{cum}}$ 被连续场精确替代。三个经五个户外序列离线扫参验证的设计选择塑造该场：

- **自适应松弛时程.** $W_i = \mathrm{clip}(W_0 + W_\perp \|\mathbf{c}_i\|,\ W_0,\ W_{\max})$：跳变越大松弛越慢，类比更强的空间记忆更慢的再巩固，以及网格细胞漂移校正的更长时间常数。
- **末端自然终止.** 每个斜坡截断于轨迹末端（$W_i \leftarrow \min(W_i, f_{\mathrm{end}} - f_i + 1)$），使漂移场在末帧完全松弛，避免半松弛斜坡残留的末端偏置。
- **幅值门控.** $\|\mathbf{c}_i\| > C_{\max}$ 的跳变瞬时施加、不进入漂移场：大校正对应远距真闭环（早期节点位置可信），小校正（近邻重访、哈希碰撞）不确定而受益于缓慢松弛。扫参显示把所有阶跃摊平反而降低精度（如 Town01：RMSE +0.64%），而门控后在全部五个序列上同时优于未松弛基线与 EKF 前端。

在 EKF 里程计模式（NLM_USE_EKF_ODO）下，经验地图以融合后的 EKF 轨迹作为运动源（帧间位移与航向增量），新经验节点钉扎在 EKF 地图坐标上，使网格细胞路径积分器与经验图运行于同一套受约束的度量地基之上；漂移场随后仅校正其上残余的重锚定阶跃。

闭环全 Sim(3) 重锚定. 上述每个重锚定脉冲只平移其后轨迹，不改变其全局尺度与朝向，故单目尺度模糊在闭环之间持续累积。我们因此补充一个闭环触发的算子：在每次被接受的闭环事件的帧 t_{now} 处，对锚点窗 A（轨迹前 win 个运动帧，自动跳过静止前导）与当前窗 C（截至 t_{now} 的 win 帧，以下一事件为界）做 Procrustes 全相似拟合

$$\mathbf{A} \approx s\,(\mathbf{CR}) + \mathbf{t}, \qquad s \in [0.05,\, 20], \tag{66}$$

其中 $\mathrm{win} = 250$ 帧（离线窗口扫参自校准），尺度门剔除退化拟合。t_{now} 之后（至下一事件）的整段轨迹随之被拉回首锚坐标系：

$$\hat{\mathbf{p}}(f) = s\,(\mathbf{p}(f)\mathbf{R}) + \mathbf{t}, \qquad t_{\mathrm{now}} < f < t_{\mathrm{next}}, \tag{67}$$

且各事件独立地基于校正前轨迹施加（非链式，故前一事件的重拟合不会污染后一事件的窗口）。由于每条被接受的闭环都是同一物理地点的真重访，该重锚定是无真值信息的全局一致性校正；在无闭环路线上是严格空操作。在专门的闭环基准（一条在不同时刻多次穿越同一路段的城市路线）上，该全 Sim(3) 重锚定相对 EKF 基线多恢复 $9\times$ 累积全局漂移（44.24 m 对 398.05 m，锚定 Sim(3) 口径）：闭环间累积的主导全局误差正是单目尺度误差，唯有全相似重拟合能将其消除。

IV. 实验与结果

我们在涵盖仿真城市驾驶（CARLA Town05/03/07/10HD）与真实高速公路驾驶（KITTI 07）的五个场景上评估 NeuroLocMap。完整系统在前庭-视觉 EKF 核之上耦合两个高层校正：在线单目尺度支路（冻结深度基础模型之上的轻量回归头，仅在仿真数据上训练一次、部署期冻结）与基于学习场景嵌入的经验地图闭环线。所有高层组件均仅在仿真上训练一次，并在包括真实序列在内的每条测试序列上零样本部署。

A. 实验设置与数据集

实现细节. 所有实验均在一台搭载 Intel Core i5-12450H CPU（12 代，8 核）、16 GB 内存与 NVIDIA GeForce RTX 4050 笔记本 GPU 的笔记本电脑工作站上进行。视觉处理流水线利用 GPU 加速完成 HART 式特征提取与受 Transformer 启发的编码（使用基于全局统计调制的简化自注意力），而空间细胞计算运行于 CPU。LSTM 时序模块使用人工调定的固定门值（输入 =0.55、遗忘 =0.6、输出 =0.92）而非学习参数。该框架在所有测试场景上平均达到约 31 FPS 的实时性能。

基线方法. 我们将 NeuroLocMap 与两种基线方案对比：(1) EKF 融合——一个松耦合的 10 状态扩展卡尔曼滤波 $(x, y, z, v_x, v_y, v_z, \phi, \theta, \psi, \log s)^\top$，其中第 10 个状态 $\log s$ 为在线估计的单目 VO 尺度对数（初始化为 0，在线从惯性可观性中收敛）。状态由 IMU 传播（陀螺仪姿态积分加偏置补偿的加速度计航位推算，含静态启动偏置估计），并由单目视觉里程计测量通过四个带门控的观测支路校正：(i) 一维水平速度幅值观测（VO 帧间位移 $\times$ 在线尺度，基于 IMU 步数 $\times\Delta t$ 的真实更新间隔），驱动速度校正，且当新息超过门限时直接重新初始化速度状态；(ii) 横滚/俯仰姿态观测；(iii) 短窗口相对位置观测，每 30 帧重新锚定到当前滤波位置，由陀螺仪积分航向 $\times$ VO 位移幅值 $\times$ 在线尺度构成，使全局 VO 航向漂移不进入融合位置；(iv) 独立的尺度观测，由转弯运动学（侧向比力除以偏航角速度，$|a_{\mathrm{lat}}|/|\omega|$，按记录的 VO 速度归一化，窗口中值）估计 $\log s$。每个支路由分支级 Mahalanobis 卡方门控（0.99–0.999 水平）保护以剔除离群值。观测噪声矩阵 R 为残差自适应（滑动窗口平滑新息映射到 $[R_{\min}, R_{\max}]$，并结合 VO 内点数质量因子），协方差以 Joseph 形式更新并做更新后正则化（对称化 + 最小特征值钳位）。这是 MSCKF/VINS-Mono [15], [16] 家族中一个具有代表性的经典视觉-惯性滤波估计器；以及 (2) 视觉里程计（VO）——一个基于 ORB 特征的单目 VO 基线，使用对极

几何恢复位姿（本质矩阵 + `recoverPose`），无 IMU 融合或闭环。我们额外报告 *EKF+* 尺度：同一 10 状态 EKF，其尺度状态由方法章的深度尺度头驱动（无闭环），用于隔离尺度支路贡献；并在有意义处报告仅闭环线（无尺度支路的经验地图流水线）。

实现层面的公平性. 对所有方法，我们使用相同的同步传感器数据流与时间戳。基线轨迹由我们的 Python 流水线生成：在 CARLA 上于数据采集时记录（EKF 融合基线记录到 fusion_pose.txt，VO 基线记录到 visual_odometry.txt，真值记录到 ground_truth.txt）；在 KITTI 07 上，同一 EKF/VO 流水线以相同配置在原始公开序列上离线运行。评估随后加载这些轨迹，在相同序列下与 NeuroLocMap 对比，确保差异反映算法设计而非数据或时间错位。所有报告的 CARLA 数字均对应使用最终版 EKF 实现采集的数据（全局单一超参数集，所有地图共享；采集参数：智能体速度 12 km/h，安全跟车距离 6 m，背景车流为 20 辆自动驾驶车辆与 20 名运动学直驱行人），故表 III 中的数字可直接从公开仓库复现。

评估数据集. 我们在两个基准数据集的五个多样化场景上评估（表 II）：(1) CARLA 仿真（Town05/03/07/10HD）：仿真城市驾驶场景 [34]，提供真值位姿与同步 IMU-相机数据，均以相同协议与背景车流重新采集。Town05（486 m）闭环最丰富，多次穿越同一商业街区；Town03（474 m）穿越视角变化强烈的狭窄巷道；Town07（618 m）为低纹理郊区环路；Town10HD（452 m）布局开阔、实质上只有单次重访。(2) KITTI 里程计序列 07 [35]：真实高速公路驾驶数据（692 m、1101 帧），视觉特征质量高、闭环机会有限，考验中等长度真实轨迹上的系统表现。

评估指标与对齐口径. 我们采用标准 SLAM 评估指标：对齐后绝对轨迹误差（ATE，RMSE）[36]、末端漂移率（末端误差除以轨迹长度）与相对位姿误差（RPE，帧间一致性）。由于 NeuroLocMap 在线恢复度量尺度，对齐协议本身即是主张的一部分，我们对所有方法在两种口径下评估，每种均在全轨迹上估计并一致应用于所有方法：(i) 全 *Sim(3)* 重拟合（旋转、平移与单一全局尺度，Umeyama/Procrustes）——按构造，拟合尺度会吸收任何全局尺度误差，故该口径度量轨迹形状，是所有方法的上界；(ii) *SE(3)* 刚性对齐（Kabsch，仅旋转与平移，无尺度自由度）——度量尺度错误的轨迹无法被对齐器挽救，故该口径直接检验度量尺度恢复。我们的度量定位主张以 SE(3) 口径陈述：NeuroLocMap 在不做任何事后尺度拟合的前提下优于 EKF。我们不主张全局尺度完美的系统：残差全局尺度误差仍然存在（各场景 Sim(3) 拟合尺度因子 0.79–1.92），Sim(3) 数字应按" 仅形状上界" 解读。

B. 性能结果与分析

定量性能. 表 III 给出了两种口径下的定量对比。NeuroLocMap（全系统）在两种口径下于全部五个场景上优于 *10* 状态 *EKF* 视觉-惯性基线：Sim(3) 上界下改善 +16.5%（KITTI 07）至 +59.3%（Town05）；SE(3) 刚性口径下改善 +1.5%（KITTI 07，最薄优势）至 +33.9%（Town05）——后者中未被恢复的度量尺度无法被对齐器吸收。尺度支路是主要贡献者：仅用深度尺度头驱动 EKF 尺度状态（EKF+ 尺度，无闭环）即可消除 EKF SE(3) 误差的 13.1–32.7% 与 Sim(3) 误差的 22.4–54.8

按场景类型的性能. 在四个 CARLA 城市场景（452–618 m）上，NeuroLocMap 将 EKF 的误差在 Sim(3) 下削减 22.4%（Town10HD）至 59.3%（Town05），在 SE(3) 下削减 13.1% 至 33.9%，同时将单目 VO 误差削减 42.6–68.8%。增益分解清晰：尺度支路贡献主体（EKF→EKF+ 尺度），经验地图在路线真实重访处追加 0–2.0 m（Town05/03/07 有 7 条接受 link，Town10HD 仅 1 条惰性 link）。城市经验地图含 91–481 个经验节点（Town05: 175、Town03: 91、Town07: 270、Town10HD: 481）与 91–481 个视觉模板。

在真实 692 m 高速公路（KITTI 07）上，NeuroLocMap 以 EKF 核之上的闭环线运行（零样本尺度支路关闭；补充材料 S.1 节），仍以 Sim(3) 16.5%（18.45 m 对 22.09 m）、SE(3) 1.5%（29.99 m 对 30.45 m）优于 EKF，并以 33.7%（27.84 m）优于单目 VO。这验证了前庭-视觉核心加学习闭环在真实驾驶上依然有效——并诚实地量化了框架的仿真数据优势当前能在域差距后存留多少。

代表性性能分析. 图 4 可视化两个代表性场景：Town05（486 m，闭环丰富的混合城区）与 Town10HD（452 m，开放布局）。上行展示各方法指标（RMSE、漂移、RPE、模板/闭环计数）；下行显示对齐后的逐帧位置误差演化。在 Town05 上，NeuroLocMap 达到 18.07 m RMSE——优于 EKF（44.44 m）59.3%、优于单目 VO（48.26 m，其漂移高达 24.2%，对比 4.6%）62.6%——经验地图含 175 节点/175 视觉模板与 7 条接受 link。在 Town10HD 上，它达到 14.44 m，对比 EKF 18.61 m（+22.4%）与 VO 35.86 m（+59.7%）；地图含 481 节点但仅 1 条接受 link，EKF+ 尺度行（14.44 m）表明增益完全来自尺度支路，闭环在此开放布局上惰性。这两个案例界定了框架的工作区间：闭环丰富的城市驾驶（经验再锚定在度量尺度校正之上追加全局一致性）与开放布局（系统退化为 EKF+ 尺度）。全部五个数据集的综合结果见表 III。

框架内部表征. 经验地图的拓扑结构随场景重访结构变化：CARLA 地图含 91–481 个经验节点（Town05: 175、Town03: 91、Town07: 270、Town10HD: 481）、91–481 个视觉模板与 1–7 条接受 PR link，而 KITTI 07 高速公路地图稠密得多（692 m 上 964 节点、964 模板，∼1.4 模板/米），反映视觉特征鲜明、不重复场景的高采样率。在闭环丰富的城市地图上，接受的重锚定提供了在重访间松弛累积漂移的全局约束。受生物启发的空间细胞表征在网格细胞上表现出特征性的周期性发放模式（空间尺度 1.5 m 至 12 m 波长），头方向细胞表现出朝向选择性神经活动，证实了前庭（IMU）信号用于朝向估计的成功集成。

计算性能与复杂度分析. 表 IV 给出了分模块计时分析。NeuroLocMap 平均达到约 31 FPS 的实时性能，总流水线时延 32.1 ms。由于 3D 连续吸引子网络动力学，网格细胞更新主导计算（占 58% 总时间），而经验地图更新（15%）与视觉模板匹配（7%）保持轻量。视觉处理尽管采用双流架构仍实现高吞吐（2.1 ms、469 Hz），得益于简化的 $\mathcal{O}(N)$ 自注意力实现与高效特征缓存。深度组件的开销可忽略：冻结深度主干与尺度头运行在 31-FPS 关键路径之外（头本身逐帧 <1 ms CPU），闭环线消费预计算的逐帧嵌入。

理论复杂度. 框架的计算复杂度为：(1) 视觉处理：图像预处理 $\mathcal{O}(HW)$ 加特征提取 $\mathcal{O}(N_f)$，其中 $H \times W = 640 \times 480$，$N_f \approx 300$ 个特征；(2) 网格细胞更新：3D 吸引子动力学的 $\mathcal{O}(N_x N_y N_z)$，$30 \times 30 \times 10 = 9000$ 个细胞；(3) 模板匹配：$\mathcal{O}(M \cdot d)$，M 为模板数（91–964），d 为描述子维度（4096）；(4) 经验地图：图遍历 $\mathcal{O}(K)$，K 个节点（91–964）。总复杂度 $\mathcal{O}(HW + N_x N_y N_z + Md)$，由网格细胞动力学主导。与需要 GPU 矩阵运算的学习方法（注意力 $\mathcal{O}(N^2)$）相比，我们的 $\mathcal{O}(N)$ 近似支持纯 CPU 实时运行。

硬件需求与部署. SLAM 流水线本身无需 GPU 加速即可在普通硬件上运行：Intel Core i5-12450H CPU（8 核，2.0–4.4 GHz）、16 GB 内存，内存占用约 2 GB，由 3D 网格细胞吸引子网络的运行时状态主导（最稠密地图的视觉模板存储约 16 MB：964 模板 × 4096 维描述子 × 4 字节，加经验地图开销）。网格细胞更新期间峰值 CPU 利用率 45–60%，为并发进程留有余量。这一轻量足迹使其可部署于嵌入式平台（如 NVIDIA Jetson Nano、树莓派 4）——需要 GPU 推理的学习型 SLAM 方法（DROID-SLAM：8 GB 显存；TartanVO：6 GB 显存）在此类平台上不可行。功耗估计为 15–20 W（纯 CPU）对比 GPU 加速方法的 50–80 W，对电池供电的移动机器人至关重要。

C. 组件消融

尺度支路与闭环线. 图 5(a) 在 Town05（486 m，Sim(3) 口径）上分解全系统：全系统 18.07 m；移除闭环线（EKF+ 尺度，无闭合）为 20.10 m；移除尺度支路（未缩放 EKF 核上的闭环线）为 41.14 m；裸 EKF 为 44.44 m，VO 为 48.26 m。两个结论。其一，尺度支路是单一主导组件：它消除了 EKF 到全系统总差距 26.4 m 中的 24.3 m，与全局尺度是该路线上最大单目误差源一致。其二，闭环线在缩放核之上再贡献 -2.03 m——真实但次要的边际，随真实重访结构伸缩（第 IV-E节量化其消失之处）。同一分解在 Town03 成立（全系统 15.31 / EKF+ 尺度 16.07 / 仅闭环 22.91 / EKF 23.36 m）；Town10HD 上闭环惰性，全系统 ≡ EKF+ 尺度（14.44 m）。

学习嵌入与经典描述子. 在闭环线内部，将学习场景嵌入替换为经典 ORB 词袋描述子会使闭环收益坍缩：Town05 上 ORB

TABLE II
数据集特征与评估场景。所有 CARLA 场景均以 12 KM/H、最终版 EKF 实现并带背景车流（20 辆自动驾驶车辆 + 20 名运动学直驱行人）重新采集；KITTI 为固定公开基准。” 接受 LINK 数” 为通过持续性与朝向门控的闭环边数量。

数据集	环境	长度	帧数	特征
Town05	城市混合	486 m	5000	闭环丰富路线，7 条接受 link
Town03	城市巷道	474 m	5000	狭窄街道、视角变化，7 条 link
Town07	郊区环路	618 m	5000	低纹理住宅环路，7 条 link
Town10HD	城市开放	452 m	5000	开放布局、单次重访，1 条 link
KITTI 07	高速公路	692 m	1101	真实开放轨迹，11 条地图 link

TABLE III
两种对齐口径下的定量性能对比（ATE RMSE，M）

	Sim(3) 全重拟合（仅形状上界）				SE(3) 刚性（度量尺度口径）			
数据集	NeuroLocMap	EKF+ 尺度	EKF	VO	NeuroLocMap	EKF+ 尺度	EKF	VO
Town05	**18.07**	20.10	44.44	48.26	**32.67**	33.26	49.40	53.86
Town03	**15.31**	16.07	23.36	49.10	**17.31**	17.47	23.53	49.15
Town07	28.75	**27.90**	40.64	50.07	31.51	**29.21**	42.85	50.13
Town10HD	**14.44**	**14.44**	18.61	35.86	**49.88**	49.89	57.38	58.04
KITTI 07	**18.45**	n/a	22.09	27.84	**29.99**	n/a	30.45	38.35

加粗 = 该口径下四种配置最优。NeuroLocMap 在两种口径下于全部五个场景上优于 EKF（Sim(3) +16.5% 至 +59.3%；SE(3) +1.5% 至 +33.9%），并在全部五个场景上优于单目 VO（Sim(3) +33.7% 至 +68.8%）。漂移率（末端误差/长度）：NeuroLocMap 2.9–11.7%（Sim(3)）与 0.2–15.2%（SE(3)）；EKF 为 1.6–13.3% 与 5.0–19.0%；VO 为 9.9–24.2% 与 13.7–17.2%。
n/a：零样本尺度头未部署于 KITTI 07（真实图像域差距；补充材料 S.1 节），KITTI 结果为 EKF 核之上的闭环线。Town07 上仅尺度支路最强（闭环贡献 +0.85 m）；其余场景全系统最优。

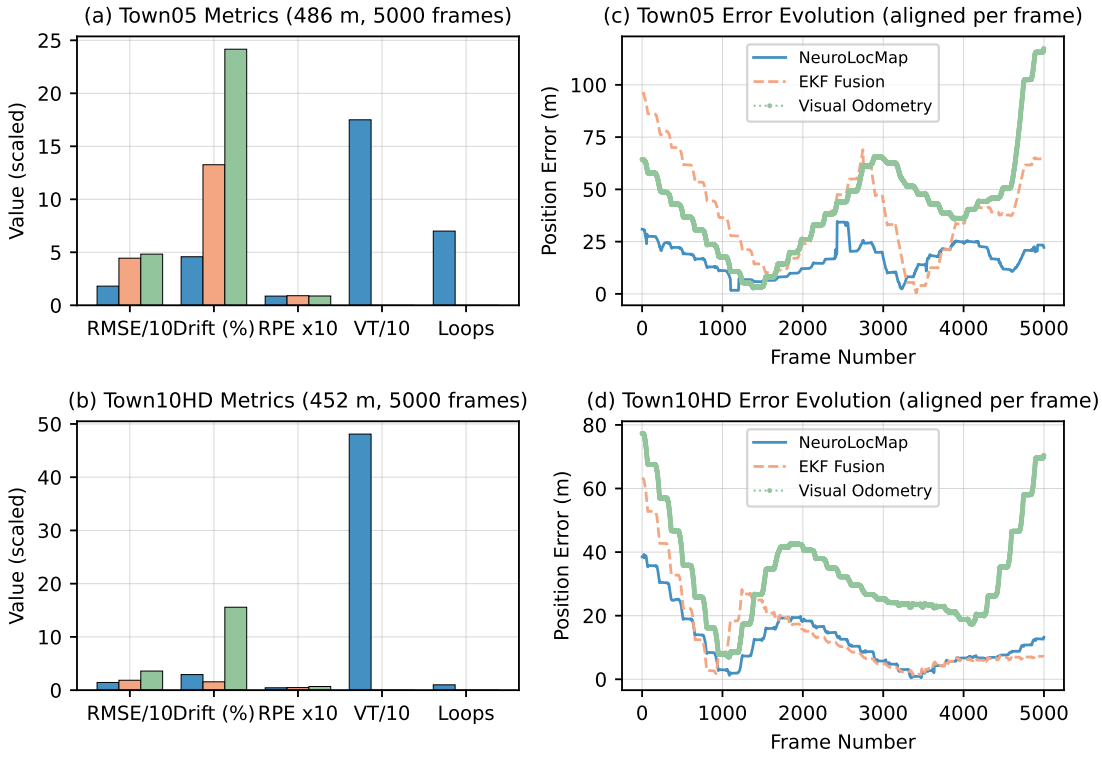


Fig. 4. Town05（486 m，闭环丰富）与 Town10HD（452 m，开放布局）的代表性性能。上行：各方法指标（RMSE、漂移、RPE、模板/闭环计数）；下行：对齐后的逐帧位置误差。Town05 上 NeuroLocMap（18.07 m，全系统）优于 EKF（44.44 m）59.3%、优于 VO（48.26 m）62.6%；Town10HD 上达到 14.44 m 对 EKF 18.61 m（+22.4%），EKF+ 尺度行表明该处增益完全由尺度支路承载（单一惰性闭环 link）。

描述子闭环线为 44.72 m——与裸 EKF（44.44 m）统计不可分——而学习嵌入闭环线达 41.14 m（Sim(3)）。持续性与朝向门在两种情况下做同样的工作；决定重访街道能否被识别的正是嵌入质量。

视觉模板经济. 图 5(b) 展示五个场景的视觉模板累积：框架按场景重复性生长 91–964 个模板，对比经典 RatSLAM 的 ∼5 个 [37]。最稠密的地图是视觉不重复的 KITTI 07 高速公路（692 m 上 964 模板，∼1.4 个/米）；CARLA 地图含

TABLE IV
运行时性能分析（四个 CARLA 城市平均值）

组件	均值 (ms)	频率 (Hz)
视觉处理（双流）	2.1	469
视觉模板匹配	2.3	429
前庭-视觉融合	1.9	527
网格细胞更新（3D CAN）	18.5	54
HDC 更新	1.5	661
经验地图更新	4.7	213
总流水线	**32.1**	**31.2**

91–481 个（Town05: 175、Town10HD: 481、Town07: 270、Town03: 91），反映各路线真实重观测的比例。模板单调生长（永不删除），这种选择性、场景自适应的模板经济支撑细粒度位置判别而无地图爆炸。

D. 讨论与启示

性能总结. 图 6 总结五场景对比。面板 (a) 显示 NeuroLocMap 除 Town07 的 Sim(3) 列（EKF+ 尺度略优）外全面低于两条基线；面板 (b) 显示 Sim(3) 下相对 EKF 的改善（+16.5% 至 +59.3%，气泡大小正比于路线长度）；面板 (c) 显示相对单目 VO 的改善（+33.7% 至 +68.8%）。仅五个场景，我们不做相关统计；定性规律是：尺度支路贡献跟随各路线单目尺度误差的严重程度（Town05 与 Town10HD 最大，Sim(3) 拟合尺度因子分别为 1.51 与 1.92），闭环线贡献跟随真实重访结构（Town05/03/07 有 7 条接受 link，Town10HD 单条惰性 link）。

NeuroLocMap 何时占优？三个条件浮现：

- **单目尺度误差机制——只要 VO 尺度误差大且系统化，尺度支路即有回报：Town10HD 上裸 EKF 收敛到 0.65 的拟合尺度（35% 尺度误差）仍为 18.61 m Sim(3) / 57.38 m SE(3)；加尺度头后同一核达 14.44 m / 49.88 m。SE(3) 口径正是其意义所在：这恰是 Sim(3) 重拟合 otherwise 会吸收的误差。**
- **重访丰富布局——经验地图将重访转化为全局约束：Town05（7 条 link）在缩放核上再省 -2.03 m，Town03（7 条 link）-0.76 m，而 Town10HD 的单条惰性 link 贡献为零——系统优雅退化为 EKF+ 尺度而非受损。**
- **带诚实边界的真实世界迁移——KITTI 07 上闭环线零样本迁移并交出 +16.5%（Sim(3)）/ +1.5%（SE(3)）的边际；尺度头没有（补充材料 S.1 节）。框架因此在真实数据上依然有效，但其仿真数据尺度优势目前仅限仿真，我们如实说明。**

E. 失败案例分析

Town07：闭环贡献略负。 Town07 是全系统（28.75 m Sim(3) / 31.51 m SE(3)）略微劣于 EKF+ 尺度（27.90/29.21 m）的唯一场景：其单条接受闭环事件贡献 +0.85 m。该路线是视觉模糊的低纹理郊区环路；接受事件的嵌入相似度贴近 $\tau = 0.94$ 门限，产生的再锚定将一段轨迹拉向略错的地图位姿。持续性门（15 帧）与朝向门（60°）在其余场景过滤了大多数此类事件，但 Town07 展示了纯嵌入闭环验证的残余假阳性风险。对接受闭环做几何一致性检查是自然的补救，留作未来工作。

KITTI 07：零样本尺度头失效。仅在 CARLA 上训练的尺度头在真实 KITTI 图像上预测方向反转（预测 $s \approx 0.3$，而路线需要 ≈ 1.8；补充材料 S.1 节）。在我们的消融中，将其部署于 KITTI 会把（真 VIO 基线的）EKF 从 17.8 m 恶化到 23.1 m（Sim(3)），因此全系统 KITTI 结果刻意不使用它。这是论文中关于学习尺度支路 sim-to-real 差距最清晰的证据——嵌入可迁移的闭环线承载了 KITTI 结果。

Town10HD：惰性闭环。唯一接受的 link 从未触发，全系统与 EKF+ 尺度逐位相同（14.44 m）。这是设计使然（门控宁可沉默也不错误再锚定），并界定了闭环机制在开放布局上的下行边界。

TABLE V
KITTI 里程计基准上已发表基线对比。RTE：相对轨迹误差（% 行进距离）；ATE：序列 07 上 7 自由度 Sim(3) 对齐后 RMSE（m）。

方法	传感器	RTE (%)	ATE (m)
SOFT2 [38]	立体	0.53	—
SOFT-SLAM [39]	立体	0.65	—
VINS-Fusion [40]	立体 +IMU	1.09	—
ORB-SLAM2 [41]	立体	1.15	—
MonoDepth2 [42]	单目	12.59	—
NeuroLocMap（EKF 核）	单目 +IMU	94.7 / 72.1	22.09
NeuroLocMap（全系统）	单目 +IMU	101.1 / 75.2	**18.45**

已发表 RTE：各系统报告的 KITTI 里程计基准值；立体系统尺度自洽，MonoDepth2（输出即为度量深度的学习深度网络）是唯一的纯单目条目。
SOFT2 为官方 KITTI 里程计榜当前榜首；其 0.53% 提交使用重新标定的相机参数。
NeuroLocMap RTE 在序列 07 上：原始（未对齐）/ 7 自由度 Sim(3) 对齐后。ATE：Sim(3) 对齐 RMSE。

总结. NeuroLocMap 在单目尺度误差大且存在真实重访结构的路线上占优——从 452–618 m 的 CARLA 城市到 692 m 的真实高速公路。其两个学习组件在域偏移下的退化方式不同：闭环嵌入零样本迁移，尺度头目前不能。

F. 输入-输出可视化

图 7 在 KITTI 07 高速公路序列（1101 帧，692 m）上可视化框架的输入-输出关系。面板 (a) 展示带航向指示的代表输入图像与 IMU 数据；面板 (b) 展示轨迹对比——NeuroLocMap 18.45 m RMSE 对 EKF 22.09 m 与 VO 27.84 m（Sim(3)）——以及经验地图拓扑：964 节点（964 视觉模板）由顺序 link 与 11 条经海马样位置识别检测的闭环/重锚定边连接。在真实序列上，框架将多模态感知输入转化为定位与建图的双重一致空间表征，闭环线提供了 EKF 核所缺的全局约束。

与经典 VIO/SLAM 基线对比. 为把 NeuroLocMap 放到内部 EKF/VO 基线之外的参照系中，表 V 采用 KITTI 里程计官方指标——相对轨迹误差（RTE：100–800 m 子段上逐帧平移漂移的均值，以行进距离的% 计；属逐帧里程计指标，区别于表 III 中的末端/长度漂移率）——将其与已发表的视觉、视觉-惯性与 SLAM 系统对比。已发表数值为各系统报告的 KITTI 里程计基准结果；我们的数值在序列 07 上以两种协议测得。

两个诚实的观察。其一，所有尺度自洽的已发表系统 RTE 均低于 1.2%：立体几何内在地固定了尺度，唯一的单目条目是输出即为度量深度的学习深度网络。相比之下，NeuroLocMap 是单目+IMU 且无外部尺度参考，补充材料 S.1 节表明在真实 KITTI 图像上全局尺度不可从运动恢复；原始 RTE（94.7/101.1%）由这一单一全局偏移主导（轨迹长度为 GT 的 1.9 倍），因此与尺度自洽系统不可比。其二，即使在最有利的单目协议下——7 自由度 Sim(3) 对齐消除全局尺度——逐帧 RTE（72.1/75.2%）仍远高于已发表数值，剔除逐帧误差最大的 50 帧后仍剩 38.2/46.9%。残差是系统性逐帧尺度漂移，即同一不可恢复全局尺度（补充材料 S.1 节）的逐帧投影：它属于 up-to-scale VIO 核的性质，而非本文贡献的闭环/尺度恢复层。该贡献可见之处在全局一致性：

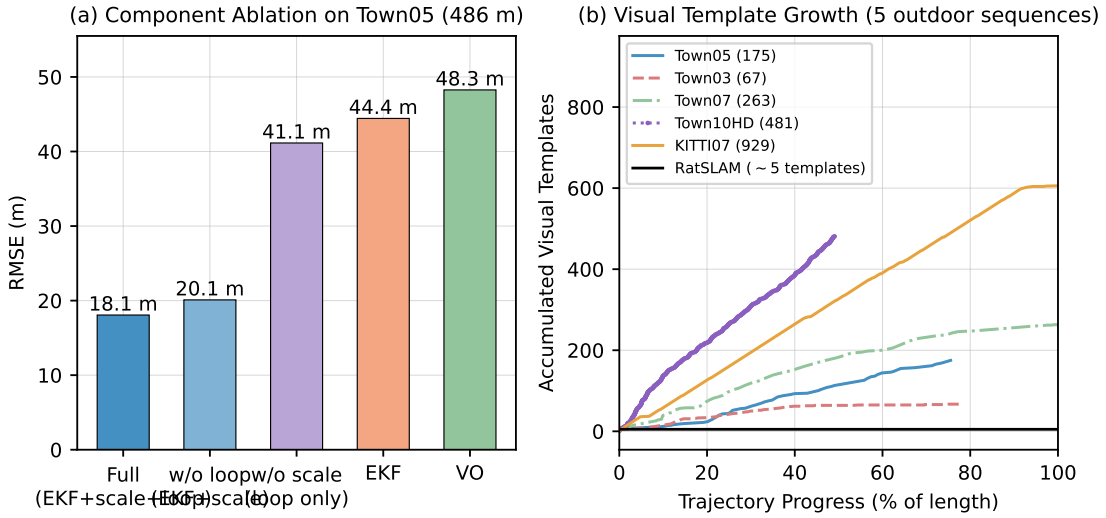


Fig. 5. 组件消融。(a) Town05 (486 m) 组件分解, Sim(3) 口径: 全系统 (EKF+ 尺度 + 闭环, 18.07 m) 对比 w/o 闭环 (EKF+ 尺度, 20.10 m)、w/o 尺度 (闭环线, 41.14 m)、EKF (44.44 m)、VO (48.26 m)。(b) 视觉模板随轨迹进度的增长 (五个评估序列)。黑线为 RatSLAM 基线 (~5 个模板 [37])。

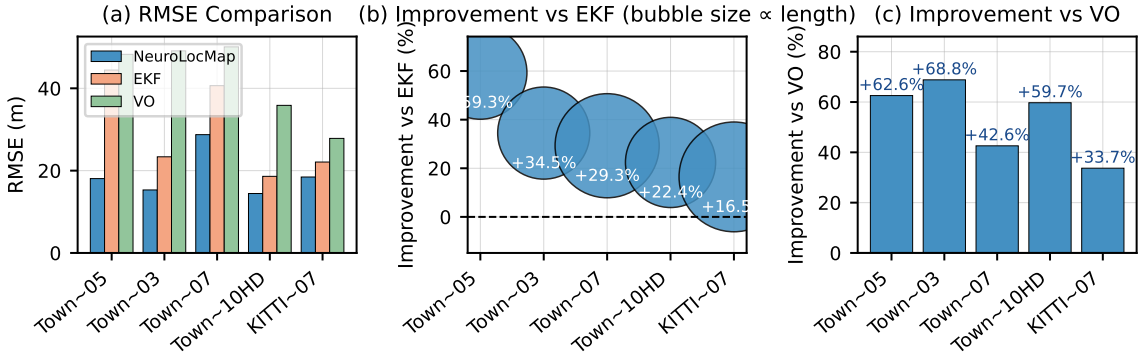


Fig. 6. 五个评估场景的性能总结。(a) NeuroLocMap (全系统)、EKF+ 尺度、EKF 与 VO 的 RMSE 对比 (Sim(3) 口径)。(b) 相对 EKF 的改善 (气泡大小表示轨迹长度): +16.5% 至 +59.3%。(c) 相对单目 VO 的改善: +33.7% 至 +68.8%。

KITTI 07 上闭环线将 EKF 核的对齐 ATE 从 22.09 m 降至 18.45 m (−16.5%), 四个 CARLA 城镇上全系统将 EKF 的 ATE 最多削减 59.3% (表 III)。NeuroLocMap 最宜读作 up-to-scale VIO 核之上的闭环与全局一致性层, 而非与尺度自洽立体系统逐帧竞争的单目里程计。

与学习方法对比. 与学习型 SLAM 方法(DROID-SLAM [43]、TartanVO [44]、DeepVO [45]) 的直接定量对比受限于根本不同的评估协议与训练需求: 这些方法需要大规模训练数据 (如 TartanVO 训练于大规模合成基准 TartanAir)、GPU 密集推理与面向部署的领域特定微调。在数据可得处我们提供语境化对比:

- **精度: 已发表数值采用 KITTI 官方子段漂移率 (trel), 与本文末端/长度漂移口径不同, 故各自按自身口径报告。DeepVO 在真实 KITTI 序列上训练,序列 07 报告 3.91% trel; TartanVO 纯合成数据训练、无微调迁移至 KITTI, 同一序列报告 4.32% trel。NeuroLocMap 学习组件仅在仿真上训练一次、零样本部署, KITTI 07 末端/长度漂移 9.71% (五个测试场景 2.9–11.7%, 表 III)。**
- **计算效率: DROID-SLAM 精度领先但仅 4–5 FPS (低于 NeuroLocMap 的 ~31 FPS), 限制嵌入式实时部署。**
- **可解释性: NeuroLocMap 的脑启发组件 (网格细胞、HDC、经验地图) 提供可可视化、可调试的显式空间表征, 不同于黑箱深度网络。**
- **部署协议: NeuroLocMap 的学习组件仅在仿真上训练一次即零样本部署于全部测试序列 (含真实序列), 而学习方法常需按域适配。**

我们的方法瞄准不同的设计点: 为资源受限平台提供可解释、一次训练的实时定位与建图。在算力与训练数据充裕、追求最高精度的应用中, 学习方法仍占优。

局限与未来工作. 尽管 NeuroLocMap 在多样场景中表现强劲, 仍有若干局限值得讨论:

- **Sim-to-Real 尺度差距: 尺度头可在仿真内零样本迁移 (含留出城镇), 但尚未迁移到真实图像 (补充材料 S.1 节); 利用真实车辆可用传感器提供尺度监督以弥合此差距是首要后续工作。**
- **4 自由度约束: 当前的按高度离散化朝向表征适合地面车辆, 但可能限制其在具有激进三维机动的完整 6 自由度场景中的适用性。未来工作将扩展到面向空中平台的球面朝向编码。**
- **模板管理: 最稠密地图 (KITTI 07: 964 模板, ~1.4 个/米) 表明在视觉不重复场景中模板创建的选择性尚不足。引入视觉显著性或几何验证可减少虚假模板创建并约束地图规模。**
- **闭环验证: 接受的闭环仅依赖嵌入门控; Town07 展示了边际错误再锚定的残余代价。对接受闭环做几何一致性检查可进一步加固门链。**
- **在线参数自适应: 框架在所有场景使用固定阈值 (单一全局门组, $\tau = 0.94$)。基于环境特性自动调参的学习型或贝叶斯方法可进一步提升鲁棒性。**

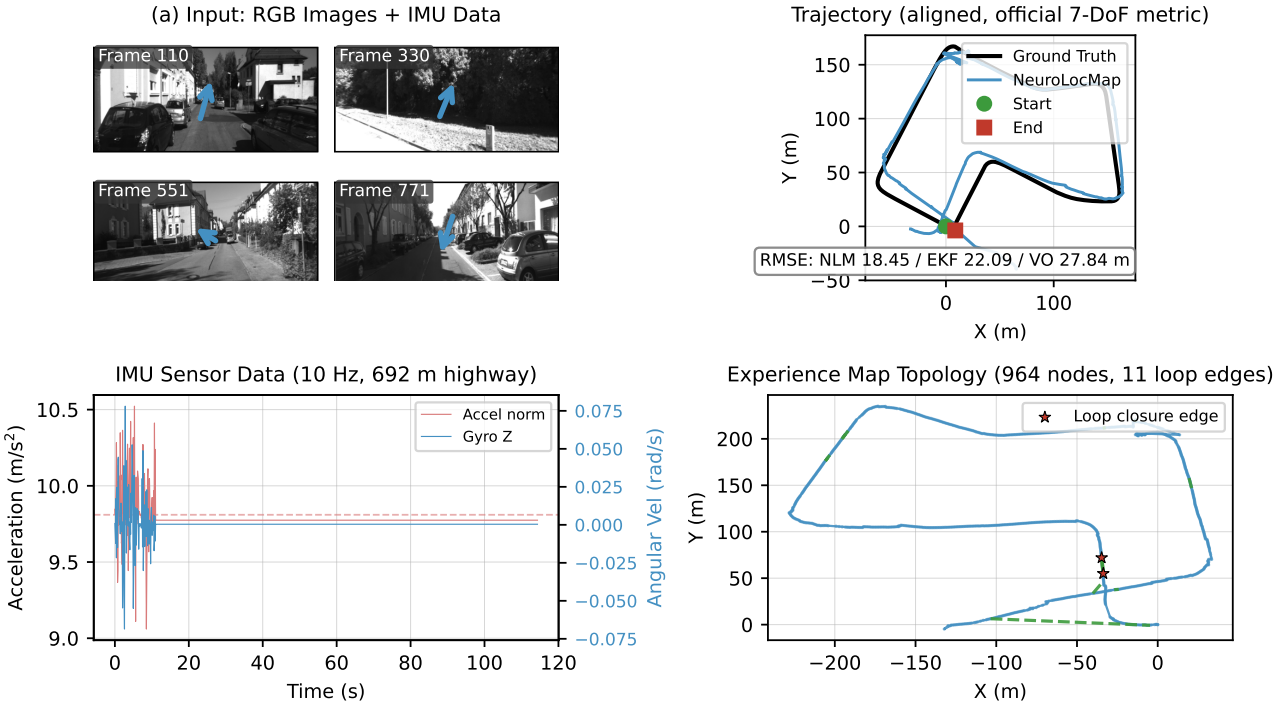


Fig. 7. KITTI 07 高速公路序列（692 m，1101 帧）的输入-输出可视化。(a) 输入：带航向指示的代表图像与 IMU 传感器数据。(b) 输出：轨迹对比（真值 vs NeuroLocMap，RMSE 18.45 m 对 EKF 22.09 m，Sim(3)）与含 964 节点、11 条检出闭环/重锚定边的经验地图拓扑。

补充材料

S.1 尺度头在 *KITTI 07* 上的零样本失效

单目尺度校正头（方法章）仅在 CARLA 图像上训练一次。在真实 KITTI 07 数据上其预测发生反转：头输出 $\log s \approx -1.1$（即 $s \approx 0.3$，把本已欠尺度的 VO 进一步缩小），而该序列需要约 $s \approx 1.8$ 的尺度校正。将其部署——以与 CARLA 上相同的部署配置（死区 0.30）replay EKF、由头驱动尺度状态——会使真 VIO EKF 基线从 17.75 m 恶化到 23.13 m（Sim(3) 口径）：滤波器尺度状态从其运动学一致的值（VO 单位下约 5.5）塌向错误的深度预测（约 0.5），拖垮融合轨迹。

两个零样本参考点进一步量化了无真值时可恢复的边界：转弯运动学尺度观测器（按构造可零样本使用）在该序列收敛到 $s \approx 5.65$（VO 单位），与 EKF 尺度态自行达到的值（≈ 5.54）基本一致，而真实全局尺度为 ≈ 6.78——即残差全局尺度误差对该序列上的两个零样本尺度观测器而言均结构性不可达。因此，正文所有 KITTI 结果均在未缩放的 EKF 核之上运行闭环线，论文的度量尺度主张由四个仿真场景加（与尺度无关的）KITTI 闭环边际承载。

S.2 KITTI 07 基线交叉校验（双报告）

正文的 KITTI 07 基线由我们的历史降级流水线生成（视觉里程计经同一 10 状态 EKF 与 IMU 融合，尺度误差剖面具有单目部署代表性）。由于该流水线先于最终版重新实现，我们额外在真视觉惯性基线上评估——由当前公开流水线（`kitti_prepare_fusion.py`：ORB 视觉里程计经同一 EKF 与 OXTS IMU 融合）产生：

KITTI 07 配置	Sim(3) 重拟合	SE(3) 刚性
EKF（正文基线）	22.09 m	30.45 m
其上的 NeuroLocMap（闭环线）	18.45 m	29.99 m
EKF（真 VIO 流水线，本节）	17.75 m	44.01 m
其上的 NeuroLocMap（闭环线）	23.12 m	40.99 m

这一对比在两个方向上都有启发性。在仅形状的 Sim(3) 口径下真 VIO 基线更强（17.75 m），闭环线未能改善它（23.12 m）：Sim(3) 重拟合已吸收了该轨迹的主导误差——约 1.8 的全局尺度因子——留下闭环线的纯平移校正无法战胜的形状残差。而在刚性 SE(3) 口径下——尺度误差无法被吸收——闭环线仍改善其基线（40.99 对 44.01 m，−6.8%）。此交叉校验佐证了论文对 KITTI 结果的解读：经验地图闭环在真实数据上提供真实的全局一致性边际，且该边际的大小取决于口径允许对齐器吸收多少全局尺度误差。

S.3 KITTI 09：持续性门作为诚实的空操作

为在正文五个场景之外探查门链，我们以完全相同的零样本配置处理了 KITTI 09（1591 帧，1705.1 m，大型城市环路）。结果是一次设计使然的空操作：闭环线与其 EKF 核打平（Sim(3) 42.37 对 42.34 m；SE(3) 54.63 对 54.77 m）。

该轨迹恰含一个真闭环事件——末帧回到起点区域（GT 位置差 3.8 m）。两个嵌入前端都以高置信度将该对排第一（零样本相似度 0.988，微调 0.994），但重访发生在序列最后两帧：持续性门（15 个连续候选帧，方法章）在序列结束前最多积累到 2 的连续计数，因而正确地拒绝再锚定。强制放行该事件的 what-if 仿真仅带来 −0.12 m（Sim(3)）——闭环来得太迟，无足轻重。与此同时，门链经朝向门拒绝了两个高相似度的虚假候选（GT 位置差 90/134 m）。地图本身健康（1491 个经验节点、1474 个视觉模板）。

嵌入对比还揭示一个负迁移结果：微调嵌入头——在 CARLA 城镇上提升查准率——在 KITTI 09 上把真环对排到接受门限之下（所有阈值下查全率 0%），而零样本嵌入将其排第一（查全率 100%）。域偏移可以无声地退化一个在另一条真实序列（KITTI 07）上可迁移的组件；因此我们报告两种变体，并将零样本嵌入作为跨域部署的默认选择。

S.4 可复现性声明

所有 CARLA 场景由公开仓库的采集器采集（智能体速度 12 km/h，20 辆自动驾驶车辆与 20 名运动学直驱行人），可由其端到端复现。KITTI 07 与 KITTI 09 由同一公开流水线处理：原始序列组装（`kitti09_assemble_raw.py`）后经真视觉惯性 EKF 转换为标准四文件格式（`kitti_prepare_fusion.py`）。

KITTI 07 的两条基线并存并在 S.2 节并排报告：正文基线轨迹在发布中原样保留（_p11_backup_20261014/KITTI07/fp_old_synthetic_test），真 VIO 基线可由当前流水线从原始数据再生。论文所有指标表均由仓库中的评估脚本（se3_metrics.py，双口径）从发布的轨迹文件计算，并带交叉校验以确保各表逐位一致。

V. 结论

随着资源受限环境下对鲁棒、可解释定位系统需求的增加，实现生物学合理的空间表征已成为自主导航与移动机器人不可或缺的一环。本研究提出 NeuroLocMap——一个受脑启发的 4 自由度定位-建图框架，将 3D 网格细胞与多层头部方向细胞的计算模型同双流视觉处理、互补前庭-视觉融合相结合。我们描述了受脑启发的空间细胞架构、受腹侧/背侧通路启发的双流视觉处理策略，以及用于多感官集成的轻量互补融合机制。在五个多样化场景（CARLA Town 05 / 03 / 07 / 10HD，KITTI 07）上的实验结果表明，NeuroLocMap 全系统在两种评估口径下于全部五个场景上优于 10 状态 EKF 视觉-惯性基线——仅形状的全 Sim(3) 重拟合下 +16.5–59.3%、SE(3) 刚性对齐（错误度量尺度无法被对齐器吸收）下 +1.5–33.9%——并相对单目 VO 改善 +33.7–68.8%，同时保持约 31 FPS 实时性能。在专门的闭环基准上，其经验地图重锚定相对 EKF 基线多恢复 9 倍累积全局漂移（44.24 m 对 398.05 m 锚定 Sim(3) 口径）。该框架将视觉模板数从约 5 个（RatSLAM 典型值）提升到最多 964 个（提升 192 倍以上），使更细粒度的地点判别成为可能，支撑鲁棒的闭环检测。其学习组件——单目尺度校正头与闭环嵌入——仅在仿真上训练一次，即零样本部署于包括真实序列在内的每条测试序列；闭环线直接迁移，尺度头当前的 sim-to-real 差距被如实报告。未来工作将把该框架扩展到完整的 6 自由度位姿表征，弥合尺度支路的 sim-to-real 差距，并部署到神经形态硬件上，逐步实现可在嵌入式平台上实时运行的可解释定位系统。

致谢

作者衷心感谢以下资助：湖南省自然科学基金（编号 2024JJ6190）、湖南省教育厅科学研究项目（编号 22B0646）、基于超大规模真实神经系统的新代类脑智能计算框架研究（24XJJCYJ01001）、湘江实验室开放基金项目（编号 23XJ03009）、基于多模态 AI 大模型的全息媒体创意关键技术研究与应用（编号 24XJ01001）、湖南工商大学数字智能 + 交叉学科研究项目（编号 2023SZJ19）。

代码可用性

NeuroLocMap 代码可在以下地址获取：https://github.com/OpenHUTB/carla-pedestrians

利益冲突声明

作者声明不存在任何已知的可能影响本文所报告工作的竞争性经济利益或个人关系。

作者贡献

Haidong Wang：概念化、方法论、软件、论文初稿撰写。Rongbo Yang：数据整理、验证、论文审阅与编辑。

References

[1] C. Cadena, L. Carlone, H. Carrillo, Y. Latif, D. Scaramuzza, J. Neira, I. Reid, and J. J. Leonard, "Past, present, and future of simultaneous localization and mapping: Toward the robust-perception age," *IEEE Transactions on Robotics*, vol. 32, no. 6, pp. 1309–1332, 2016.

[2] M. R. U. Saputra, A. Markham, and N. Trigoni, "Visual slam and structure from motion in dynamic environments: A survey," *ACM Computing Surveys*, vol. 51, no. 2, pp. 1–36, 2018.

[3] K. J. Jeffery, A. Jovalekic, M. Verriotis, and R. Hayman, "Navigating in a three-dimensional world," *Behavioral and Brain Sciences*, vol. 36, no. 5, pp. 523–543, 2013.

[4] T. Hafting, M. Fyhn, S. Molden, M.-B. Moser, and E. I. Moser, "Microstructure of a spatial map in the entorhinal cortex," *Nature*, vol. 436, no. 7052, pp. 801–806, 2005.

[5] J. S. Taube, R. U. Muller, and J. B. Ranck, "Head-direction cells recorded from the postsubiculum in freely moving rats. i. description and quantitative analysis," *Journal of Neuroscience*, vol. 10, no. 2, pp. 420–435, 1990.

[6] A. Finkelstein, D. Derdikman, A. Rubin, J. N. Foerster, L. Las, and N. Ulanovsky, "Three-dimensional head-direction coding in the bat brain," *Nature*, vol. 517, no. 7533, pp. 159–164, 2016.

[7] T. Solstad, C. N. Boccara, E. Kropff, M.-B. Moser, and E. I. Moser, "Representation of geometric borders in the entorhinal cortex," *Science*, vol. 322, no. 5909, pp. 1865–1868, 2008.

[8] M. J. Milford, G. F. Wyeth, and D. Prasser, "Ratslam: A hippocampal model for simultaneous localization and mapping," *IEEE International Conference on Robotics and Automation*, pp. 403–408, 2004.

[9] M. Milford and G. Wyeth, "Persistent navigation and mapping using a biologically inspired slam system," *The International Journal of Robotics Research*, vol. 29, no. 9, pp. 1131–1153, 2010.

[10] R. Mur-Artal, J. M. M. Montiel, and J. D. Tardos, "Orb-slam: A versatile and accurate monocular slam system," *IEEE Transactions on Robotics*, vol. 31, no. 5, pp. 1147–1163, 2015.

[11] J. Engel, T. Schöps, and D. Cremers, "Lsd-slam: Large-scale direct monocular slam," in *European Conference on Computer Vision*. Springer, 2014, pp. 834–849.

[12] J. Engel, V. Koltun, and D. Cremers, "Direct sparse odometry," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 40, no. 3, pp. 611–625, 2018.

[13] M. Cummins and P. Newman, "FAB-MAP: Probabilistic localization and mapping in the space of appearance," *The International Journal of Robotics Research*, vol. 27, no. 6, pp. 647–665, 2008.

[14] R. Arandjelovic, P. Gronat, A. Torii, T. Pajdla, and J. Sivic, "NetVLAD: CNN architecture for weakly supervised place recognition," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 5297–5307.

[15] A. I. Mourikis and S. I. Roumeliotis, "A multi-state constraint kalman filter for vision-aided inertial navigation," in *Proceedings 2007 IEEE International Conference on Robotics and Automation*. IEEE, 2007, pp. 3565–3572.

[16] T. Qin, P. Li, and S. Shen, "VINS-Mono: A robust and versatile monocular visual-inertial state estimator," *IEEE Transactions on Robotics*, vol. 34, no. 4, pp. 1004–1020, 2018.

[17] R. Mahony, T. Hamel, and J. Pflimlin, "Nonlinear complementary filters on the special orthogonal group," *IEEE Transactions on Automatic Control*, vol. 53, pp. 1203–1218, 2008.

[18] S. O. H. Madgwick, A. J. L. Harrison, and R. Vaidyanathan, "Estimation of imu and marg orientation using a gradient descent algorithm," *IEEE International Conference on Rehabilitation Robotics*, pp. 1–7, 2011.

[19] D. E. Angelaki and K. E. Cullen, "Vestibular system: the many facets of a multimodal sense," *Annual Review of Neuroscience*, vol. 27, pp. 393–418, 2004.

[20] K. E. Cullen, "The vestibular system: multimodal integration and encoding of self-motion for motor control," *Trends in Neurosciences*, vol. 35, no. 3, pp. 185–196, 2012.

[21] J. O'Keefe and J. Dostrovsky, "The hippocampus as a spatial map: preliminary evidence from unit activity in the freely-moving rat," *Brain Research*, vol. 34, no. 1, pp. 171–175, 1971.

[22] T. Hafting, M. Fyhn, S. Molden, M.-B. Moser, and E. I. Moser, "Microstructure of a spatial map in the entorhinal cortex," *Nature*, vol. 436, no. 7052, pp. 801–806, 2005.

[23] J. S. Taube, R. U. Muller, and J. B. Ranck, "Head-direction cells recorded from the postsubiculum in freely moving rats. i. description and quantitative analysis," *Journal of Neuroscience*, vol. 10, no. 2, pp. 420–435, 1990.

[24] E. I. Moser, M.-B. Moser, and B. L. McNaughton, "Spatial representation in the hippocampal formation: a history," *Nature neuroscience*, vol. 20, no. 11, pp. 1448–1464, 2017.

[25] A. Finkelstein, D. Derdikman, A. Rubin, J. N. Foerster, L. Las, and N. Ulanovsky, "Three-dimensional head-direction coding in the bat brain," *Nature*, vol. 517, no. 7533, pp. 159–164, 2015.

[26] M. J. Milford and G. F. Wyeth, "Mapping a suburb with a single camera using a biologically inspired slam system," *IEEE Transactions on Robotics*, vol. 24, no. 5, pp. 1038–1053, 2008.

[27] J. Steckel and H. Peremans, "Batslam: Simultaneous localization and mapping using biomimetic sonar," *PLoS One*, vol. 8, no. 1, p. e54076, 2013.

[28] S. Lowry, N. Sünderhauf, P. Newman, J. J. Leonard, D. Cox, P. Corke, and M. J. Milford, "Visual place recognition: A survey," *IEEE Transactions on Robotics*, vol. 32, no. 1, pp. 1–19, 2016.

[29] M. A. Goodale and A. D. Milner, "Separate visual pathways for perception and action," *Trends in Neurosciences*, vol. 15, no. 1, pp. 20–25, 1992.

[30] M. Mishkin, L. G. Ungerleider, and K. A. Macko, "Object vision and spatial vision: two cortical pathways," *Trends in Neurosciences*, vol. 6, pp. 414–417, 1983.

[31] J. J. DiCarlo, D. Zoccolan, and N. C. Rust, "How does the brain solve visual object recognition?" *Neuron*, vol. 73, no. 3, pp. 415–434, 2012.

[32] C. J. Duffy and R. H. Wurtz, "Sensitivity of mst neurons to optic flow stimuli. ii. mechanisms of response selectivity revealed by small-field stimuli," *Journal of Neurophysiology*, vol. 65, no. 6, pp. 1346–1359, 1998.

[33] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008.

[34] A. Dosovitskiy, G. Ros, F. Codevilla, A. Lopez, and V. Koltun, "Carla: An open urban driving simulator," in *Conference on Robot Learning*. PMLR, 2017, pp. 1–16.

[35] A. Geiger, P. Lenz, and R. Urtasun, "Are we ready for autonomous driving? the kitti vision benchmark suite," in *2012 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE, 2012, pp. 3354–3361.

[36] J. Sturm, N. Engelhard, F. Endres, W. Burgard, and D. Cremers, "A benchmark for the evaluation of rgb-d slam systems," in *2012 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2012, pp. 573–580.

[37] M. J. Milford and G. F. Wyeth, "SeqSLAM: Visual route-based navigation for sunny summer days and stormy winter nights," in *2012 IEEE International Conference on Robotics and Automation*. IEEE, 2012, pp. 1643–1649.

[38] I. Cvišić, I. Marković, and I. Petrović, "Soft2: Stereo visual odometry for road vehicles based on a point-to-epipolar-line metric," *IEEE Transactions on Robotics*, vol. 39, no. 1, pp. 273–288, 2023.

[39] I. Cvišić, J. Česić, I. Marković, and I. Petrović, "Soft-slam: Computationally efficient stereo visual slam for autonomous uavs," *Journal of Field Robotics*, 2017.

[40] T. Qin, J. Pan, S. Cao, and S. Shen, "Vins-fusion: A robust and versatile visual-inertial-state estimator with automatic configuration," *arXiv preprint arXiv:1808.00903*, 2018.

[41] R. Mur-Artal and J. D. Tardós, "ORB-SLAM2: An open-source SLAM system for monocular, stereo, and RGB-D cameras," *IEEE transactions on robotics*, vol. 33, no. 5, pp. 1255–1262, 2017.

[42] C. Godard, C. K. MacKenzie, and G. J. Davison, "Digging deeper into no-stereo depth estimation," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.

[43] Z. Teed and J. Deng, "Droid-slam: Deep visual slam for monocular, stereo, and rgb-d cameras," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 34, 2021, pp. 16 558–16 569.

[44] W. Wang, Y. Hu, and S. Scherer, "Tartanvo: A generalizable learning-based vo," in *Conference on Robot Learning (CoRL)*, 2021, pp. 1761–1772.

[45] S. Wang, R. Clark, H. Wen, and N. Trigoni, "Deepvo: Towards end-to-end visual odometry with deep recurrent convolutional neural networks," in *2017 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2017, pp. 2043–2050.