2.2 相关工作

本节将主要介绍与该研究相关的工作，包括人工智能和神经科学关系的背景、视觉目标跟踪中的深度学习网络和人类的平滑跟踪。

2.2.1 人工智能和神经科学

由于大脑是唯一已知的真正通用智能的样例，人类在某些能力方面拥有卓越的性能，所以人们也想让人工设计的智能体也具备这样的能力。神经科学领域的发现能够启发新的深度模型架构或损失函数设计。神经科学对人工智能的影响，可以类比于飞鸟对制造飞机的启发。反过来，由于人工智能的研究和发展不需要受限于生物大脑和社会伦理的限制，比如实验条件、结构约束等，可以仿照生物学规律进行模型的设计，实验得出的结论可以反过来促进人们对大脑未知领域的理解，实现人工智能和神经科学发展的相互促进。

本章实验的数据是利用神经科学中常用的功能性核磁共振成像（functional Magnetic Resonance Imaging，fMRI）来收集人进行单目标跟踪时大脑皮层的活动。其中核磁共振为磁矩不为零的原子核[1]，在外部磁场影响下自旋能级会产生塞曼分裂[2]，共振吸收部分射频辐射的过程[3]。在神经科学领域，核磁共振成像（Magnetic Resonance Imaging，MRI）提供内部结构的图片，扫描脑灰质、白质、脑脊液的形态结构，而功能性核磁共振成像是根据大脑执行特定任务时局部脑区血氧水平产生的改变，来观察执行特定任务时“脑激活”的状况，可以显示活动水平非常细微变化的成像，时间分辨率为秒级。

2.2.2 深度跟踪神经网络

最近许多工作表明，显著目标是通过一系列中心凹视图提取得到的[107,108]。BTN 中的目标提取模块是用一个在神经解剖学上可解释的二维高斯滤波器[109] 进行实现。在目标跟踪中关注特定的外观表示与关注空间特征一样重要。具有递归的方法可以自适应地改变卷积模块的滤波器，因此可以将其更改为图像帧上的表示并优化模型性能[110]。动态滤波器网络（Dynamic Filter Network，DFN）[111]的滤波器是根据输入特征在线获得的，使用 DFN 可以在不降低精度的情况下实现模型压缩。依赖于输入的状态转换可以帮助学习马尔可夫决策模型[112]，在这里不直接使用该结果，而是使用这个思想来进行显著特征的预测。

在视觉目标跟踪任务中，一般很适合使用循环结构和显著性目标，但是它们只能

[1]原子核为带正电的粒子，不能自旋的原子核没有磁矩，能够自旋的原子核拥有电流，所以产生相应地磁场，并形成磁矩。

[2]即塞曼效应，表示原子的光谱在外磁场中出现分裂，产生的跃迁是原子核自旋在核塞曼能级上发生的跃迁。

[3]其共振频率波段处于射频段，由于人体中氢原子丰度高，临床使用氢原子共振，共振频率是42.58MHz/T，其他磁场强度按比例折算。

在简单背景的单色视频中表现很好[109]。一些工作[113]通过目标检测器的表示获得了显著目标的结果，并将目标检测器的结果作为循环神经网络（Recurrent Neural Network，RNN）的输入[114]。但是，这个方法需要处理每个完整的视频帧。最近的一项研究[115]明确利用 RNN 来建模人类的注意力机制。本文的研究类似于循环注意力模型[109]，并利用长短时记忆网络（Long Short-Term Memory，LSTM）实现的人类注意力来更好地提取多帧中的运动特征。此外，本章尝试设计一个类脑跟踪网络，该网络将获得更好的 BTS 并在 Tracking-Gump 数据集上超越现有的跟踪模型[85]。

2.2.3 平滑跟踪

通常使用人工合成刺激来研究人眼凝视，比如研究眼跳采用改变目标位置时眼睛注视的形式，而研究平滑跟踪则使用线性或者正弦运动的点。使用人工合成数据最大的优势是拥有定义良好的属性和明显特征，特定的特征简化了眼球跟踪和血氧水平依赖信号的分析的过程。通过仅仅沿着一个独立的特征位置，可以进行理想的刺激调制，能更加精确地建立起特定脑区之间激活的联系。但这些优势所牺牲的是人工合成数据并不能代表人类正常的视觉，实际有效的视觉输入会更加复杂，并且动态开放的环境中平滑跟踪不会单独出现，而是和眼跳和注视的序列混在一起。因此，在单一背景上的人工合成刺激忽略了可能的背景信息、拥挤效应和全部眼睛运动规划流程的影响。另外一个缺点是长时间的跟踪单一背景下的人工合成刺激会导致人注意力维持的降低。

特别是日常生活中，在动态背景上进行平滑跟踪，并行处理互相冲突的信息通常是必要的，这种情况下可能在不同方向上包含多个移动的目标。值得注意的是从猴子的研究中得出结论：V5 不仅在平滑跟踪中，而且即使在视网膜上冲突时不同刺激之间的相互作用中也发挥重要的作用[116]。然而，在自然条件下处理平滑跟踪眼睛运动所引起的动态视觉输入时必须非常小心。然而即使是对于非常大且多样的数据集，最近计算机视觉领域所取得的进步已经开始能够自动理解动态开放的场景。相比于人工合成

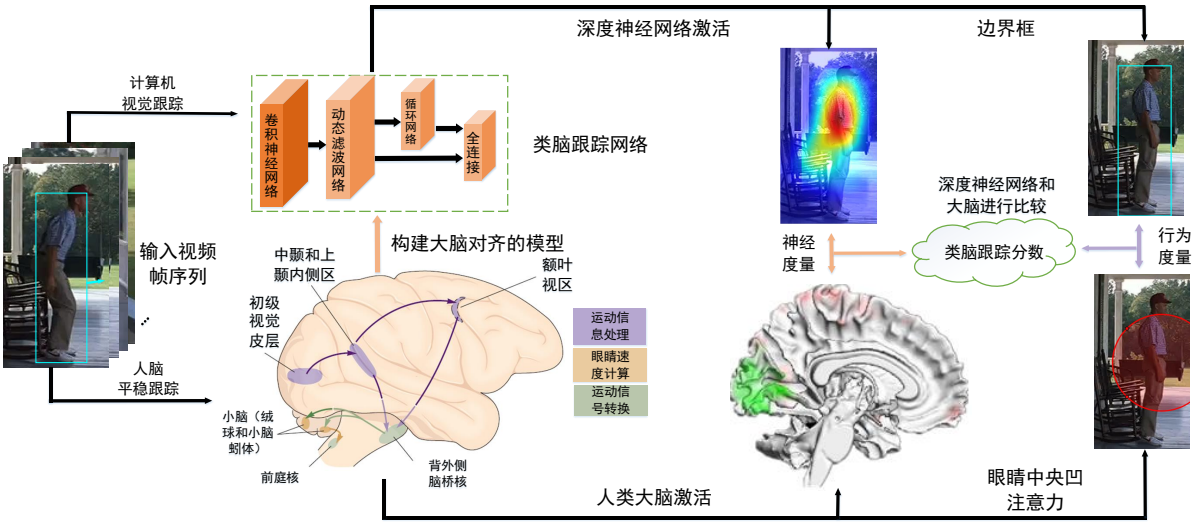

图 2.1 神经解剖学对齐的深度神经网络协同设计

的刺激，当使用不受限的动态自然刺激，在实验中如何利用运动眼睛的显示指令（比如："跟踪这个点"、"当目标出现时进行眼跳"等），将凝视轨迹分成不同眼睛运动成分仍然很有挑战。手动标注"真实数据"被认为是眼睛运动成分分类的黄金标准，对于每一秒的凝视信号，只有注视和眼跳能在 4 到 15 秒的时间内到达场景的任何地方[117]。比如，StudyForrest 数据集中提供了大约 30 小时的 fMRI 和同步的凝视记录[85]。因此，StudyForrest 数据集同时记录了视觉和非视觉线索相关的脑部激活，可以用来更好的进行眼睛运动成分的分类。

最近几年在眼睛运动数据，特别是平滑跟踪的自动识别分析中取得了很大的进展。基于部分或全部真实值标注好的大规模数公开据集，提出了一些眼睛跟踪分类算法[117–120]。因为之前大多数分类算法是基于静态刺激进行开发，所以仅仅标注了注视和眼跳。因此这些算法会错误地将平滑跟踪分类成注视或者眼跳，阻止了与平滑跟踪相关激活的识别。为了解决这个问题开发了自动多观察者平滑跟踪算法（Multi-Observer Smooth Pursuit，MOSP），该算法能够以较高的分类精度区分三种主要的眼睛运动，分别是注视、眼跳和平滑跟踪[120,121]。

在本章的研究中利用了最新提出的几种眼动识别方法。使用最先进的计算机视觉和眼睛运动分类算法，从大规模的 StudyForrest 数据集中分析了凝视和 fMRI 记录，并能够在动态开放的自然场景（好莱坞电影）中识别与平滑跟踪和眼跳眼睛运动相关的大脑区域。

2.3 类脑跟踪网络

在本节中分三步介绍所提出的 BTN。首先简要指出了设计类脑模型的动机和准则，其次详细介绍了 BTN 模型中的每个模块，最后介绍用于训练 BTN 的损失函数。

2.3.1 设计准则

该研究设计的目标是在视觉目标跟踪的深度神经网络（Deep Neural Networks，DNN）模型和大脑中的平滑跟踪通路之间获得高度的相似性，同时遵循两个准则来设计 BTN[122]：

(1) **结构**：在跟踪性能相差不多的模型架构中，一般更加倾向于使用类脑模型，因为它模型复杂度低、更容易理解并且可以满足大脑的解剖约束。使用深度神经网络是因为它们的神经元是数据处理的基本单元，并且深度神经网络中的所有神经激活都可以清晰地映射到大脑皮层激活[103]。除此之外，由于视频序列中的时间属性，视觉目标跟踪自然会考虑使用循环连接。同时背侧通路的激活也具有时间属性，因此也假定 BTN 会为时间序列生成激活响应。

(2) **功能**: 在类脑模型中，满足神经解剖学约束的中间层激活响应和最终输出行为会有更准确的结果，这使得设计的类脑模型能够更好地预测视觉皮层的激活和人眼的

运动行为，能同时满足计算机视觉目标跟踪预测和神经科学平滑跟踪预测的需求。

大脑中平滑跟踪运动的目的是转动眼球使移动目标的图像在人眼中央凹上的位置保持不变。如图 2.1 所示，在平滑跟踪的大脑通路中，初级视觉皮层 (V1) 是对输入信号进行第一阶段的预处理， MT/MST 整合了空间中的运动信息，而额叶视区（Frontal Eye Field，FEF）生成预测性眼球运动信号[123–125]。

受大脑中平滑跟踪通路的启发，构建从大脑皮层区域（图 2.1 下部）到深度神经网络层（图 2.1 上部）的神经解剖映射。通过量化的大脑相似性分数，并利用所获得的皮层解剖知识来启发 BTN 的设计。 BTN 包括映射到人脑的四个区域：初级视觉皮层 (V1)，中颞区和上颞内侧区（MT/MST）、额叶视区（FEF）和脑干/小脑。 $\mathrm{CONV_{V1}}$ 是经典的卷积层，执行预处理以减少数据大小。 $\mathrm{DFN_{MT/MST}}$ 是动态滤波器网络，$\mathrm{RNN_{FEF}}$ 是循环神经网络。对于最左边的输入刺激，右上角的两个图像分别表示大脑对齐模型中的深度神经网络的激活响应和边界框，而右下图的两个图像分别表示跟踪时大脑皮层的激活和眼睛注视的位置，同时 BTS 显示了计算机视觉跟踪性能与大脑跟踪响应之间的相似性关系。为了比较模型，通过检查 DNN 中各层的激活来构建到皮层的映射，以便能够很好地理解特定大脑皮层区域中的激活，理想情况下，这种大脑皮层激活不需要多余参数的类脑模型所预测得到，将会降低传统深度跟踪模型的冗余度。因此如图 2.2 所示，BTN 由卷积层、DFN、LSTM 和全连接（Fully Connected，FC）层四个神经网络模块组成，它们类比于平滑跟踪通路中的 V1、MT/MST、FEF、脑干/小脑，其中脑干/小脑是运动预测器，将 FEF 的输出转换为相应的运动响应。这种明确的大脑分区思想是设计类脑跟踪模型重要的一步，并且致力于寻找更通用的网络结构。整个模型包括在皮层区域没有差异的神经网络，以及各种改进 BTN 的连接。

2.3.2 BTN 架构

首先简要介绍 BTN 的处理流程，如图 2.2 所示，在平滑跟踪中发挥特定作用的大脑皮层区域用矩形框表示。对于给定的输入帧 F_t 和注意力参数 a_t，模仿空间注意力的中央凹从 F_t 中选择包含目标的局部区域视图 f_t。此外，在考虑外观特征 α_t 的基础上，使用包括初级视觉皮层 V1 的背侧和腹侧通路的外观选择器，获得跟踪目标更加精细的特征 m_t，并在 LSTM 中更新隐藏状态 h_t。并将 FEF 的输出 o_t 和背侧流输出 d_t 合并输入到脑干/小脑模块中进行解码，来预测下一帧的空间注意力 a_{t+1} 、外观注意力 α_{t+1}、眼位校正信号 Δp，甚至眼球运动信号 Δp_t。所有黑色箭头表示信息在同一个时间步内流动，而灰色箭头代表不同时间步之间的连接。下面详细介绍类脑跟踪架构的每个模块。

2.3.2.1 视网膜和背侧/腹侧通路

视网膜上的空间选择器为当前帧 F_t 选择中央凹视图 f_t，它的输出被输入到两条相互连接的腹侧/背侧通路。腹侧通路识别被跟踪的目标，而背侧通路学习被跟踪目标的运动特征。腹侧/背侧通路中的外观注意力由当前帧自下而上的中心凹视图信息 f_t 和前

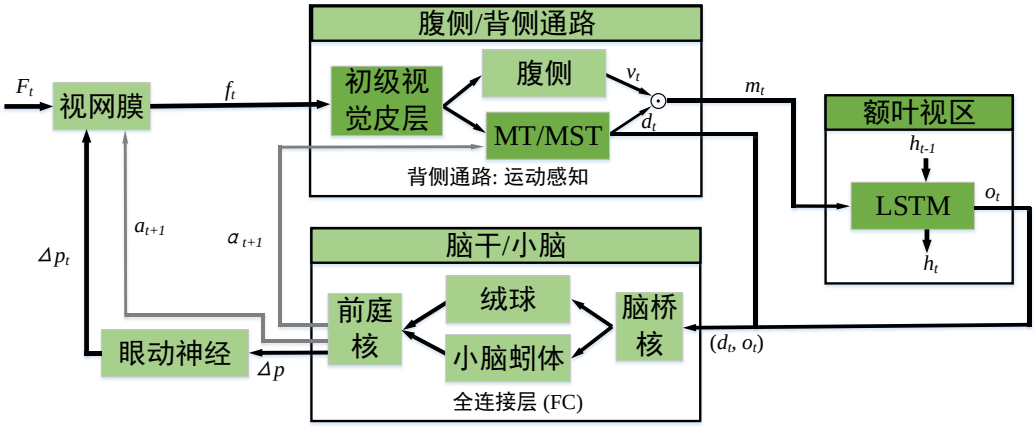

图 2.2 类脑视觉目标跟踪的网络架构

一帧自上而下的外观注意力信息 α_{t+1} 所驱动。然而，中央凹的空间注意力只依赖于空间注意力信息 a_{t+1}，在这种情况下，自下而上的信息仅具有局部影响并依赖于某个位置的显著性输入，但自上而下的信息将全局特征结合到局部分析中[126]。

(1) **视网膜**: 在类脑模型的处理流程中，根据空间注意力机制[109] 进行建模。对于输入帧 $F_t \in R^{W\times H}$ 形成矩阵 $M_t^x \in R^{w\times W}$ 和 $M_t^y \in R^{h\times H}$，矩阵中的每一行都包含一个高斯分布。高斯分布的位置和宽度决定了输入帧的哪些部分被选为视网膜中的中央凹视图 f_t。因此，中央凹视图 $f_t \in R^{h\times w}$ 可以表示为：

$$f_t = M_t^y F_t (M_t^x)^T, \tag{2.1}$$

用连续矩阵行的分布中心、步长和方差来表示注意力。与循环注意力跟踪类似[127]，只有步长和分布中心是通过 LSTM 预测的，而方差依赖于步长。该操作在估计较小的方差时避免了过度的偏差，有助于提高学习的速度。此外，中央凹 f_t 的大小依赖于具体的实验分析。

(2) **腹侧通路**: 腹侧通路（包括初级视觉皮层 V1）将中央凹视图 f_t 转换为固定维度的外观表征向量 v_t，其中包括被跟踪目标的空间特征和外观特征，具体地网络结构依赖于具体的实验分析。在本章的腹侧通路架构中，使用卷积神经网络实现初级视觉皮层 V1，这是腹侧通路和背侧通路共享的模块。然而，通常使用若干个卷积层和最大池化层来实现模仿人类初级视觉皮层 V1[128]。在这以后，处理流程分为背侧通路和腹侧通路。最后，通过卷积神经网络提取被跟踪目标的特征 v_t，以实现腹侧通路功能。

(3) **背侧通路**: 背侧通路（包括 V1 和 MT/MST）用于提取运动特征，将显著目标 d_t 和中央凹视图中的背景进行分割。使用动态滤波网络[111] 建模背侧通路（MT/MST），用于处理中央凹视图前景和背景之间的空间关系。 FC(·) 表示全连接层，所以 MT/MST 中基于外观表示 α_t 动态预测卷积滤波器 ϕ_t 为：

$$\left\{\phi_t^i\right\}_{i=1}^N = \mathrm{FC}(\alpha_t), \tag{2.2}$$

V1 输出的的特征经过具有 N 个卷积层的非线性滤波器，然后，将其输出传递给卷积核

大小为 1×1 的卷积和 Sigmoid 激活函数，将特征转换为二维掩码 d_t。 d_t 中的每一点都表示被所跟踪目标占据的概率。

背侧通路的位置图是基于腹侧通路抽取的目标表示，这模拟了视觉系统中的噪声抑制机制。因为在当前帧没有跟踪目标的表征时，LSTM 中的目标表征不会被覆盖，所以使用这种机制可以处理遮挡和漂移的情况。因此，腹侧和背侧通路的输出可以被整合为：

$$m_t = \mathrm{FC}(conc(v_t \odot d_t)), \tag{2.3}$$

其中 $\odot$ 表示通过特征掩码执行显著目标提取的哈达玛积， $conc$ 表示将矩阵的所有行连接成向量的连接运算符。

2.3.2.2 额叶视区

所提出的类脑跟踪方法性能取决于估计下一帧中目标外观和位置的能力。因此，它在很大程度上依赖于跟踪目标状态的预测。而 LSTM 可以利用时空和外观特征，使所提出的模型能够处理遮挡和漂移的情况，例如跟踪目标被其他干扰物遮挡的情况。

如图 2.2 所示，将 LSTM 模块命名为 FEF，利用输出误差来预测眼球运动。在平滑跟踪中，FEF 区域接受来自腹侧/背侧流的输出 m_t，精调后的目标表征 m_t 用于更新 FEF 中的隐藏状态 h_t，并在 FEF 中存在类似的预测动作[123–125]。当模型训练过程中，被跟踪目标和眼球运动之间的延迟减少时，输出误差趋向于零。因此，LSTM 需要即使在没有图像输入的情况下依然能够推断眼球的运动。

$$h_t, o_t = \mathrm{LSTM}(h_{t-1}, m_t)。 \tag{2.4}$$

2.3.2.3 脑干和小脑

脑干和小脑一起（包括脑桥核、绒球、小脑蚓体和前庭核）使用全连接层进行建模，然后利用背侧流的输出 d_t 和额叶视区的输出 o_t 来估计注意力 a_{t+1} 和外观 α_{t+1}，最后通过动眼神经生成眼球运动信号 Δp_t。

$$\Delta p_t, \Delta a_{t+1}, \alpha_{t+1} = \mathrm{FC}(conc(d_t), o_t), \tag{2.5}$$

$$a_{t+1} = a_t + tanh(c)\Delta a_{t+1}, \tag{2.6}$$

其中 c 是一个可训练参数，用较小的值进行初始化以限制训练期间模型更新的大小。方程 2.4 到 2.6 描述信息更新的过程。通过累积注意力变化来计算眼睛注视的位置，如章节 2.3.3 所示，学习空间注意力来估计下一帧中被跟踪目标的位置，并预测在时间 t 相对于注意力的注视位置 p_t。

$$p_t = a_t + \Delta p_t。 \tag{2.7}$$

此外，参考脑干和小脑都可以利用反向动力学控制器进行建模的发现和想

法[129,130]，基于动力学的平滑跟踪模型[129]，这里假设反向动力学控制器是完美的，因此眼球的运动信号可以表示为：

$$\Delta p_t = \Delta p, \tag{2.8}$$

其中 Δp 是眼球运动的低通滤波器。基于这个假设，在该研究中不需要实现反向动力学控制器。

2.3.3 损失函数

可以通过优化一组损失来训练所提出的 BTN，包括跟踪损失、背侧/腹侧流损失和辅助损失。 BTN 损失 L_b 由下式给出：

$$L_b = L_t + L_d + L_v + L_a。 \tag{2.9}$$

BTN 损失的详细信息如下所述。

2.3.3.1 跟踪损失

为了达到视觉跟踪的目的，即定位目标在当前帧的位置，损失函数第一项采用预测的边界框和真实边界框之间的交并比。由于交并比对目标和图片尺寸具有不变性，用它来衡量定位跟踪目标的准确性是比较适合的。虽然交并比不对应任何概率分布并且不能被归一化，但它经常用于跟踪性能的评估[131]。同时，使用交并比的交叉熵损失函数代替传统的 L2 损失函数是由于目标定位使用 L2 损失的一个缺点是会使模型在训练过程中更偏向于尺寸更大的物体，因为大目标的 L2 损失更容易大于小目标。所以在这里根据 UnitBox[132] 将跟踪损失 L_t 表示成交并比的负对数：

$$L_t = -\log(\mathrm{IoU}(\frac{p_t \cap \hat{p}_t}{p_t \cup \hat{p}_t}))。 \tag{2.10}$$

2.3.3.2 背侧流损失

使用背侧流中的空间注意力机制从视频帧中挑选出被跟踪的目标。为了估计该模块的参数，跟踪系统必须预测目标的运动，而这个预测过程很难恢复原状。使用两项背侧流损失来保证随着关注目标区域的减少，跟踪的精度会上升。背侧流损失 L_d 的第一项限制了预测的注意力区域尽可能地覆盖目标的边界框，而第二项防止注意力区域变得太大（最大为整个输入帧的大小），这里的对数操作是为了适当的裁剪以避免数值不稳定。

$$L_d = -\log(\frac{a_t \cap p_t}{p_t}) - \log(1 - \frac{a_t \cap F_t}{a_t \cup F_t})。 \tag{2.11}$$

2.3.3.3 腹侧流损失

当被跟踪目标（比如一个特定的行人）是动态开放环境中时，设置腹侧流中外观注意力的目的是为了抑制干扰。为了达到这个目的，在外观注意力上设置一个损失函数以

选出被跟踪的目标。给定注意力区域 a 和边界框 p，记 $r(a_t, p_t) : R^4 \times R^4 \rightarrow \{0,1\}^{h_v \times w_v}$ 为目标函数，输出一个和 V1 的输出一样大的二进制掩膜。该掩膜就叫做显著目标区域 g，其中边界框和显著目标重叠的位置值为 1，其他地方为 0，也就是只保留下边界框中包含目标的像素。腹侧流损失函数可以表示为显著目标区域的预测值和前背景分割的真实值之间的交叉熵：

$$L_v = -r(a_t, p_t)\log(d_t)。 \tag{2.12}$$

2.3.3.4 辅助损失

对模型的参数 θ 和动态参数的期望值 $\phi_t(\alpha_t)$ 应用 L2 正则化。同时为了避免超参数调优，参考多任务学习[133]来学习各个损失的权重 λ。使用全为 1 的向量初始化权重后，给损失函数添加正则化项，则辅助损失 L_a 可以表示为：

$$L_a = \frac{1}{2}\|\theta\|_2^2 + \frac{1}{2}\|\phi_t\|_2^2 - \sum_i \log(\lambda_i^{-1})。 \tag{2.13}$$

2.4 大脑数据分析

为了比较 DNN 的视觉目标跟踪和人脑平滑跟踪的相似性，首先需要从各种眼球运动中提取平滑跟踪，然后选择相应的大脑区域和激活用于相似性计算。

2.4.1 视频刺激的运动估计

由于平滑跟踪行为和视频中目标的移动高度相关，首先使用计算机视觉方法对所有视频帧的运动进行估计。尽管目前已存在许多精度高的运动估计算法，但仍然会产生额外的噪声输出，所以这里使用两种不同的算法来增强运动估计的鲁棒性。第一种算法是仅对孔径问题不敏感的点（比如角点）进行运动估计，以提供稀疏光流场并估计运动[134]。首先对输入视频做采样因子为 2 的空间二次抽样，然后创建一个拥有五个空间层和两个时间层时空高斯金字塔。对于这些多尺度表征的每一层，计算每个像素的运动速度。对速度的估计值相对于原始视频分辨率进行正则化，并以类似于金字塔合成的方式合并到处理流程当中[135]，并对过高的速度值使用对应速度的百分之九十进行裁剪。第二个算法使用基于光流计算的插值方法[136]。该算法首先使用边缘保持插值的稠密匹配，然后进行能量最小化操作。最后使用这两种算法，计算出每个视频帧像素偏移的平均长度。

2.4.2 平稳跟踪样本的提取

实验中每个凝视样本都包含一个四元组：时间、显示器坐标系下的横坐标 x 和纵坐标 y、眼跟踪质量的置信度估计。因为数据集使用的是单眼跟踪，所以置信度为 1 表示好的眼跟踪，而 0 表示跟踪丢失。经数据检查后发现在所有受试中跟踪丢失的比例一般在 1.2% 和 16.7% 之间，而受试 5 和受试 20 跟踪丢失特别明显，丢失比例分别是 86.7%